Extensiones del Machine Learning

Introducción al Aprendizaje por Refuerzo

Luis Daniel Hernández Molinero
Ciencia de la Computación e Inteligencia Artificial
Dept. Ingeniería de la Información y las Comunicaciones

Universidad de Murcia

Máster en Inteligencia Artificial

2025 / 2026

Índice de Contenidos

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Desarrollo

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Introducción al Aprendizaje por Refuerzo

- **Aprender** (RAE)
  Del lat. apprehendĕre.
  1. tr. Adquirir el conocimiento de algo por medio del estudio o de la experiencia. U. t. c. intr. Hay que aprender de los propios errores.
  - Nos interesa el conocimiento adquirido desde la experiencia.
  - Solo se adquiere a través de estímulos (recompensas) de refuerzo.
- Una definición computacional:
  *El **aprendizaje por refuerzo** consiste en **aprender** de forma dirigida qué acciones debe escoger un agente software **interactuando** con el entorno, usando situaciones de aprendizaje idealizadas, **maximizando** alguna noción de "recompensa" o premio acumulado.*
- **Contexto histórico:**
  - Aprendizaje por Ensayo y Error: *Ley de Efecto (Edward Thorndike, 1900)*
  Cualquier comportamiento que es seguido por consecuencias agradables es probable que se repita y cualquiera que sea seguido por consecuencias desagradables es probable que sean evitadas.
  - Teoría del Control Óptimo:

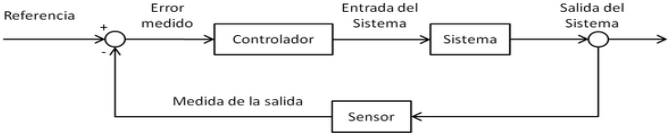

¿Quién Estudia el RL?
Silver, 2015

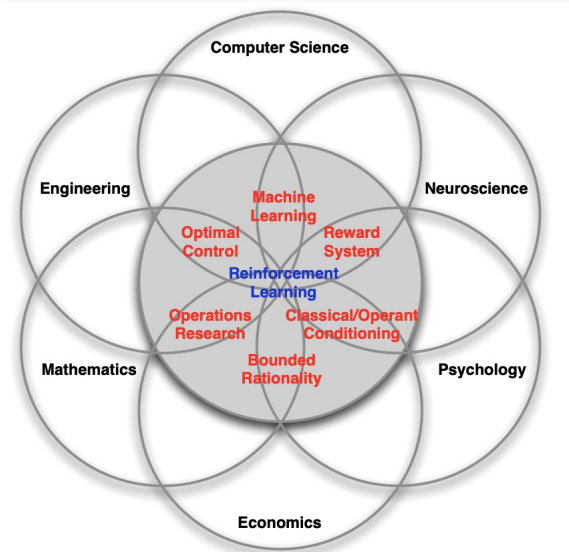

Aprendizaje por Refuerzo es otro Tipo de Aprendizaje

Silver, 2015

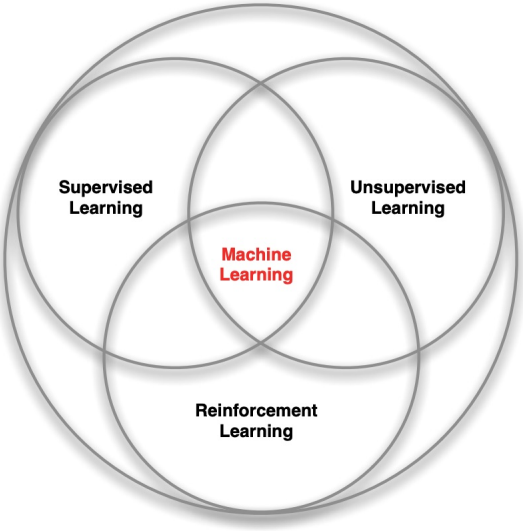

- **Supervisado:** Aprender de un conjunto de datos con sus salida (etiquetas).
  - P.e. Clasificar los datos en base a categorías conocidas.
- **No supervisado:** Aprender una estructura oculta a partir de datos no etiquetados.
  - P.e. Agrupar datos similares sin que se tenga una categoría predefinida.
- **Aprendizaje por refuerzo:**
  - No aprende de datos iid.
  - Aprender de la exploración vs explotación
  - Aprender del entorno (agente interactivo)

Algunos Ejemplo (de Control)

- Ponerse en pie una gacela recién nacida.
  - Se pone en pie en menos de 30' y está corriendo en una hora.
- **Sistemas de control** (adaptativo) industrial.
  - Controla un sistema en tiempo real sin supervisión humana (p.e. una refinería).
- Gestionar un portafolio de inversiones.
  - Debe decidir sobre cuánto invertir y en qué. P.e. (Pigorsch & Schäfer, 2022),
- **Control de aeronaves.**
  - Controlar cada una de las piruetas acrobáticas que pueden hacer un helicóptero (Andrew Y. Ng et al., 2004)
  - Controlar un planeador usando corrientes calientes de aire (Linn, 2017)
- **Jugar** al juego de backgammon, go, shogi, ajedrez, ...
  - TD-Gammon de Gerald Tesauro ganó en 1998 al campeón del mundo.
  - Alpha-Go de (Silver et al., 2016) y Alpha-Zero (David Silver et al., 2017) de David Silver et.al. (Deepmind-Google) son sistemas que han ganado a campeones el mundo.
- Hacer que un robot humanoide **aprenda a caminar**.
  - Humanoides virtuales (Nicholas Hess et al., 2017)
  - Humanoide reales (Ilija Radosavovic et al., 2023)
- **Jugar** a videojuegos
  - Puede jugar a todos los juegos de Atari. (Mnih et al., 2013)
  - Ms.Pac-Man consigue la máxima puntuación posible (Van Seijen et al., 2017)

Desarrollo

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Conceptos fundamentales

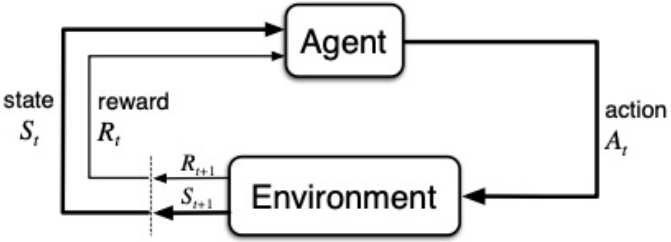

- Agente
- Acción
- Entorno
- Estado
- Recompensa

- **En cada paso t el agente:**
  - Recibe una **observación** O_t y una recompensa R_t
  - Ejecuta una **acción** A_t

- **El entorno:**
  - Recibe una **acción** A_t y modifica su estado S_t a S_{t+1}
  - Emite una **observación** O_{t+1} (y una recompensa R_{t+1})

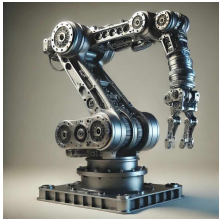

Profundizamos en ...

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Recompensas

- **Recompensa:** Es una señal de retroalimentación escalar, $R_t \in \mathbb{R}$.
- Indica cómo de bien ha hecho la acción el agente.
- **Hipótesis de la Recompensa**
  Cualquier objetivo se puede formalizar como la maximización del valor esperado de la suma acumulada de las recompensas.
  - El **retorno**, G_t, es la recompensa acumulada.
    $$G_t = R_{t+1} + R_{t+2} + R_{t+3} + \dots$$
  - El trabajo del agente es maximizar la recompensa acumulada.
- Las recompensas se asignan por objetivos, no por subojetivos.
- **Ejemplos de Recompensas:**
  - Ajedrez: Recompensa positiva por dar jaque mate, negativa si se comete un error que lleva al jaque mate del oponente, o cero si no ocurre ningún cambio significativo.
  - Brazo robótico: Recompensa cero hasta que el objeto es correctamente manipulado, y positiva cuando el objetivo es alcanzado.
  - Pac-Man: Recompensa positiva cuando el avatar come, negativas cuando no hace nada o lo comen.

Profundizamos en ...

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Acciones

- **Acción:** Las acciones, A_t, son las decisiones o movimientos que el agente puede tomar en un momento dado durante la tarea.
  - Vienen dadas por una **política**
  - La política del agente define su comportamiento y es un mapeo desde los estados a las acciones.
  - Dos casos:
    - Política determinista: $\pi(S)$
    - Política estocástica, $\pi(A|S) = p(A|S)$
- Las acciones pueden tener **consecuencias** a largo plazo.
- Se adoptan con **el objetivo de maximizar el retorno**.
- **Ejemplos de Acción:**
  - Ajedrez: Movimiento de las piezas en el tablero.
  - Brazo robótico: Modificación de la rotación de las juntas para manipular el objeto.
  - Pac-Man: Pulsar los botones del mando para controlar el movimiento dtel avatar.

Profundizamos en ...

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

El Agente y El Entorno

- **Agente:** Es la entidad que toma decisiones observando el estado del entorno y lleva a cabo las acciones en cada instante de tiempo.
  - Ejemplos de Agentes:
    - En ajedrez: el jugador humano que observa el estado de la partida y mueve las piezas.
    - En el brazo robótico: el algoritmo que ajusta las juntas del brazo para manipular el objeto.
    - En Pac-Man: el jugador o el sistema de IA que controla el avatar dentro del laberinto.
- **Entorno:** Incluye todos los elementos de la tarea que están fuera del control directo del agente.
  - Ejemplos de Entorno:
    - Ajedrez: El cronómetro y los movimientos del oponente.
    - Brazo robótico: Factores físicos como la gravedad y la fricción de los objetos.
    - Pac-Man: Los movimientos de los fantasmas y la disposición de las pastillas en el laberinto.
- Hay una interacción continua entre ellos.

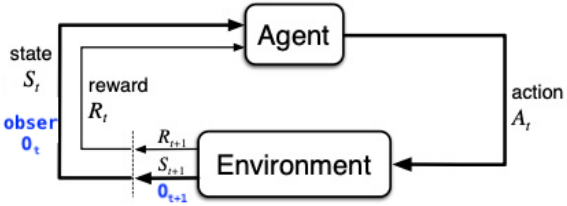

Profundizamos en ...

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Estados

- La **historia** es la secuencia de observaciones, acciones y recompensas:

$$H_t = O_1, R_1, A_1, \ldots, A_{t-1}, O_t, R_t$$

- Son todas las variables observables hasta el tiempo t.
- Lo que sucede a continuación depende de la historia:
  - El agente selecciona acciones.
  - El entorno selecciona observaciones/recompensas.
- El **estado** es la información utilizada para determinar lo que sucederá a continuación (por parte del agente/entorno).
- Formalmente, el estado es una función de la historia:

$$S_t = f(H_t)$$

Tipos de Estados

- **Estado del Entorno**, S_t^e, es la representación privada del entorno.
  - Es cualquier dato que el entorno use para seleccionar la siguiente observación/recompensa.
  - Normalmente no es visible para el agente.
  - Incluso si el conjunto S_t^e fuese visible, puede contener información irrelevante.
- **Estado del Agente**, S_t^a, es la representación interna del agente.
  - Es cualquier información que el agente use para elegir la siguiente acción.
  - Es la información utilizada por los algoritmos de aprendizaje por refuerzo.
  - Puede ser cualquier función de la historia.

- **Estado Markoviano:** Es toda la información relevante para tomar una acción. $\mathbb{P}(S_{t+1}|S_t) = \mathbb{P}(S_{t+1}|S_1, \dots S_t)$
- **¿Es observable?**
  - **Completamente**: $O_t = S_t^a = S_t^e$.
  - **Parcialmente**: El agente debe crear su propia representación S_t^a.
    - **Última observación**: $S_t^a = O_t$ (puede no ser suficiente).
    - **Historia completa**: $S_t^a = H_t$ (puede ser demasiado grande).
    - Algún estado actualizado **incrementalmente**: $S_t^a = f(S_{t-1}, O_t)$.
    - **Creencias sobre el estado del entorno**:$S_t^a = (P[S_t^e = s_1], \dots, P[S_t^e = s_n])$

- **Ejemplos de Estado:**
  - Ajedrez: Localización de las piezas en el tablero y el tiempo restante.
  - Brazo robótico: Posición del objeto a manipular y la rotación de las juntas del brazo.
  - Pac-Man: Posición del avatar, las pastillas amarillas y los fantasmas en el laberinto.

Desarrollo

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Aprendizaje y Planificación. Predicción y Control. Exploración y Explotación

- Dos problemas fundamentales en la toma de decisiones secuencial:
  - **Aprendizaje por Refuerzo**:
    - El entorno es inicialmente desconocido.
    - El agente interactúa con el entorno.
    - El agente mejora su política.
  - **Planificación**:
    - Se conoce un modelo del entorno.
    - El agente realiza cálculos con el modelo (sin ninguna interacción externa).
    - El agente mejora su política.
    - También conocido como: deliberación, razonamiento, introspección, reflexión, búsqueda.

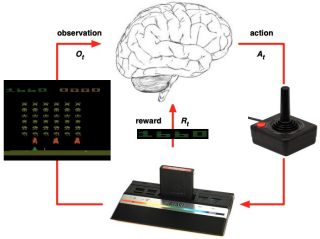

- Dos problemas fundamentales en el aprendizaje por refuerzo:
  - **Explotación**: Utiliza la información conocida para maximizar la recompensa.
  - **Exploración**: Encontrar más información sobre el entorno.
  - Hay que buscar un equilibrio entre explorar y explotar.

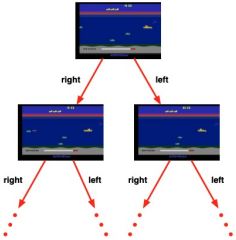

- Dos conceptos muy relacionados: Predicción/Control.
  - **Predicción**: evaluar el futuro (para una política dada).
  - **Control**: optimizar el futuro (encontrar la mejor política).
  - Están fuertemente relacionados. P.e: $\pi_*(s) = \arg\max_\pi v_\pi(s)$

Desarrollo

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Tipos de Agentes

- **Política:** Determina cómo un agente decidirá una acción para un estado particular.
- **Función valor:** Especifica el valor esperado de acumulación de recompensas futuras desde un estado particular.
- **Modelos:** Representación del entorno que permite predecir el resultado de las acciones.

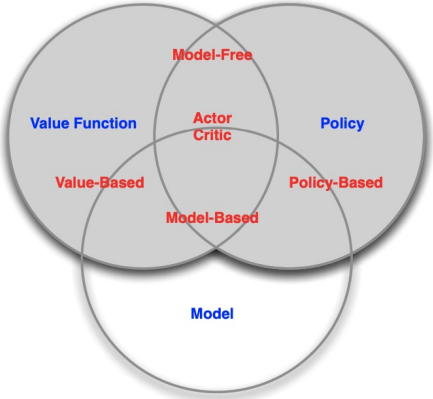

- Basado en Valores
  - Sin Política (Implícita)
  - Función de Valor
- Basado en Políticas
  - Política
  - Sin Función de Valor
- Actor-Crítico
  - Política
  - Función de Valor

- Sin Modelo (Model-Free)
  - Política y/o Función de Valor
  - Sin Modelo
- Con Modelo (Model-Based)
  - Política y/o Función de Valor
  - Con Modelo

Desarrollo

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Conclusiones

- Comprensión de los elementos básicos (recompensas, acciones, estados, agente y entorno) es esencial.
- Los conceptos de exploración vs explotación se abordarán en el problema del bandido
- Los problemas de predicción vs control se irán estudiando en paralelo.
- La taxonomía proporcionan una base para estructurar los agentes en RL.
- El aprendizaje por refuerzo es un campo con aplicaciones prácticas y teóricas amplias.

Desarrollo

1. Introducción

2. Elementos Comunes en RL
   2.1. Recompensas
   2.2. Acciones
   2.3. Agente y entorno
   2.4. Estados

3. Otros Conceptos a Destacar

4. Una Taxonomía

5. Conclusiones

6. Referencias

Referencias – I

- Andrew Y. Ng, Adam Coates, Mark Diel, Varun Ganapathi, Jamie Schulte, Ben Tse, Eric Berger & Eric Liang. (2004).Inverted autonomous helicopter flight via reinforcement learning. *International Symposium on Experimental Robotics*, 363–372.
- David Silver, Thomas Hubert, Julian Schrittwieser, Ioannis Antonoglou, Matthew Lai, Arthur Guez, Marc Lanctot, Laurent Sifre, Dharshan Kumaran, Thore Graepel, Timothy P. Lillicrap, Karen Simonyan & Demis Hassabis. (2017).Mastering Chess and Shogi by Self-Play with a General Reinforcement Learning Algorithm. *CoRR, abs/1712.01815.* http://arxiv.org/abs/1712.01815
- Ilija Radosavovic, Tete Xiao, Bike Zhang, Trevor Darrell, Jitendra Malik & Koushil Sreenath. (2023). Real-World Humanoid Locomotion with Reinforcement Learning. https://doi.org/10.48550/arXiv.2303.03381
- Linn, A. (2017). La ciencia imita a la naturaleza: investigadores de Microsoft prueban una máquina de planeo controlada por IA. https://news.microsoft.com/features/science-mimics-nature-microsoft-researchers-test-ai-controlled-soaring-machine/
- Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., & Riedmiller, M. (2013).Playing Atari with Deep Reinforcement Learning. *arXiv preprint arXiv:1312.5602.* https://www.cs.toronto.edu/~vmnih/docs/dqn.pdf

Referencias – II

- Nicholas Hess, Dhruva TB, Srinivasan Sriram, Jay Lemmon, Josh Merel, Greg Wayne, Yuval Tassa, Tom Erez, Ziyu Wang, S. M. Ali Eslami, Martin Riedmiller & David Silver. (2017).Emergence of Locomotion Behaviours in Rich Environments. *arXiv preprint arXiv:1707.02286.* https://arxiv.org/pdf/1707.02286.pdf
- Pigorsch, U., & Schäfer, S. (2022).High-Dimensional Stock Portfolio Trading with Deep Reinforcement Learning. *2022 IEEE Symposium on Computational Intelligence for Financial Engineering and Economics (CIFEr)*, 1–8. https://doi.org/10.1109/CIFEr52523.2022.9776121
- Silver, D. (2015). Lectures on Reinforcement Learning. https://www.davidsilver.uk/teaching/
- Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., van den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., et al. (2016).Mastering the game of Go with deep neural networks and tree search. *Nature, 529*(7587), 484–489. https://doi.org/10.1038/nature16961
- Van Seijen, H., Fatemi, M., Romoff, J., Laroche, R., Barnes, T., & Tsang, J. (2017). Hybrid Reward Architecture for Reinforcement Learning. En I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan & R. Garnett (Eds.), *Advances in Neural Information Processing Systems* (Vol. 30). Curran Associates, Inc. https://proceedings.neurips.cc/paper_files/paper/2017/file/1264a061d82a2edae1574b07249800d6-Paper.pdf