Aprendizaje por Refuerzo

Proceso de Decisión de Markov

Luis Daniel Hernández Molinero
Ciencia de la Computación e Inteligencia Artificial
Dept. Ingeniería de la Información y las Comunicaciones

Universidad de Murcia

Máster en Inteligencia Artificial

2025 / 2026

Índice de Contenidos

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Desarrollo

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Introducción

- Un **sistema** es un conjunto de elementos interrelacionados que funcionan como un todo para lograr un objetivo común.

  Ejemplo: Un automóvil, un reloj, una célula, etc ...

- Muchos sistemas evolucionan a lo largo del **tiempo** y presentan las siguientes características:
  - Existe **incertidumbre**: El futuro no está completamente determinado por el presente.
  - Hay **aleatoriedad**: Los eventos ocurren de forma aleatoria, siguiendo ciertas distribuciones de probabilidad.
  - La información es **incompleta**: No se conoce toda la información necesaria para hacer predicciones exactas.

  Ejemplo: Finanzas, meteorología, comunicaciones, bilogía, física, etc

- ¿Cómo estudiar estos sistemas?
  - **Objetivo:** Establecer una representación matemática (modelo) del fenómeno (sistema).
  - **Solución:** Procesos estocásticos

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Variable Aleatoria

Definición

- Una **variable aleatoria** es una función desde un espacio muestral Ω en $\mathbb{R}$.
- Un **espacio muestral** es el conjunto de los posibles **resultados** de un experimento, llamados sucesos elementales.
- La variable aleatoria asigna a $w \in \Omega$ un número real $X(w)$, de forma **atemporal**.
- Podemos extender el concepto a variable aleatoria **cualitativa**.

Ejemplo (Lanzamiento de dos monedas)

- Experimento: Lanzar dos monedas al aire.
- Espacio muestral: $\Omega = \{cc, cx, xc, xx\}$, donde c representa "sale cara" y x "sale cruz".
- Variable aleatoria X:

$$\begin{array}{rcll} X : \Omega & \longrightarrow & \mathbb{R}, & \mathbb{L}abels \\ w & \mapsto & X(w) & \\ cc & \rightarrow & 2, & 2 \text{ caras} \\ cx, xc & \rightarrow & 1, & \text{distintas} \\ xx & \rightarrow & 0, & 2 \text{ cruces} \end{array}$$

Distribuciones de Probabilidad con Variables Discretas

- $X : \Omega \to \mathbb{R}$ variable aleatoria **discreta** en el espacio de probabilístico $(\Omega, \mathbb{B}, Pr)$

  Ω: Espacio muestral, $\mathbb{B}$: σ–álgebra sobre Ω, $Pr()$: **Medida de probabilidad**.

  $$Pr : \mathbb{B} \to [0,1],\ Pr(\emptyset) = 0,\ Pr(\Omega) = 1,\ Pr(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} Pr(A_i)$$

- Función de **distribución de probabilidad** (o masa de probabilidad):

  $$p_X(k) = P(X = k) = Pr(\{\omega \in \Omega : X(\omega) = k\})$$

- Función de **distribución de probabilidad acumulada:** $F_X(x) = P(X \leq x) = \sum_{k \leq x} p_X(k)$

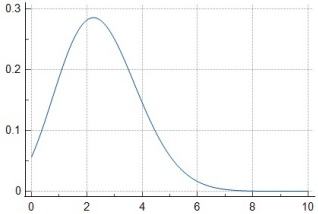

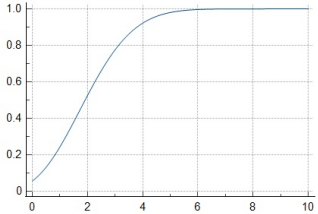

https://www.medcalc.org/

$B(n = 10, p = 0{,}25)$

- Función de **distribución conjunta** y **d.c. acumulada** de dos variables discretas:

  $$P(X = x, Y = y) = P(X = x \wedge Y = y) \qquad F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$$

- Función de **distribución condicionada** de dos variables discretas:

  $$P(X = x | Y = y) = P(X = x, Y = y)/P(Y = y)$$

Distribuciones de Probabilidad con Variables Continuas - I

- $X : \Omega \to \mathbb{R}$ variable aleatoria **continua** en el espacio de probabilístico $(\Omega, \mathbb{B}, Pr)$.
  (Se mantiene la definición de espacio probabilístico)
- Función de **distribución de probabilidad acumulada**:
  $$F_X(x) = P(X \leq x) = Pr(\omega \in \Omega : X(\omega) \leq x) = \int_{-\infty}^{x} f_X(u)du$$
- Función de **densidad de probabilidad**:
  $$f_X(x) = \frac{d}{dx} F_X(x)$$
- Función de **distribución de probabilidad**, a partir de $f_X()$:
  $$P(X \in [a, b] \subset \mathbb{R}) = \int_a^b f_X(x)\, dx = F(b) - F(a).$$

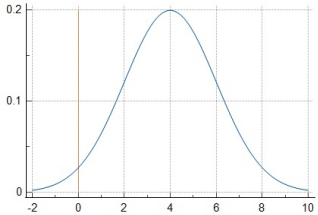

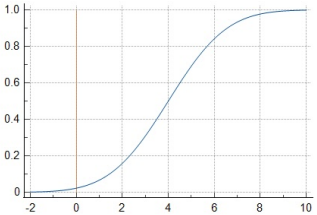

https://www.medcalc.org/
$N(\mu = 2, \sigma = 1)$

Distribuciones de Probabilidad con Variables Continuas – II

Consideremos $\mathbf{X} = (X_1, X_2, \ldots, X_n)$, n-variables continuas:

- Función de **distribución acumulada conjunta**:

$$\begin{aligned} F_{\mathbf{X}}(x_1, x_2, \ldots, x_n) &= P(X_1 \leq x_1, X_2 \leq x_2, \ldots, X_n \leq x_n) \\ &= \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \cdots \int_{-\infty}^{x_n} f_{\mathbb{X}}(u_1, u_2, \ldots, u_n)\, du_n\, du_{n-1} \cdots du_1. \end{aligned}$$

- Función de **densidad conjunta**: $f_{\mathbf{X}}(x_1, x_2, \ldots, x_n) = \dfrac{\partial^n}{\partial x_1 \partial x_2 \cdots \partial x_n} F_{\mathbf{X}}(x_1, x_2, \ldots, x_n)$.
- Función de **distribución de probabilidad conjunta**: $P(\mathbf{X} \in \mathbf{A}) = \displaystyle\int_{\mathbf{A}} f_{\mathbf{X}}(\mathbf{x})\, d\mathbf{x}$.
- Función de **densidad de probabilidad condicionada**: $f_{\mathbf{X}_{1\ldots k}|\mathbf{X}_{k+1\ldots n}}(\mathbf{x}_{1\ldots k} \mid \mathbf{x}_{k+1\ldots n})$

$$f_{X_1, X_2, \ldots, X_k | X_{k+1}, X_{k+2}, \ldots, X_n}(x_1, x_2, \ldots, x_k \mid x_{k+1}, x_{k+2}, \ldots, x_n) = \frac{f_{\mathbf{X}}(x_1, x_2, \ldots, x_n)}{f_{\mathbf{X}_{k+1\ldots n}}(x_{k+1}, x_{k+2}, \ldots, x_n)},$$

- Función de **probabilidad condicionada**:

$$P(\mathbf{X}_{1\ldots k} \in A \mid X_{k+1} = x_{k+1}, X_{k+2} = x_{k+2}, \ldots, X_n = x_n) = \int_A f_{\mathbf{X}_{1\ldots k}|\mathbf{X}_{k+1\ldots n}}(\mathbf{x}_{1\ldots k} \mid \mathbf{x}_{k+1\ldots n})\, dx_1\, dx_2 \cdots dx_k.$$

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Representación Matemática con el Tiempo

- $X(w)$, v.a., asigna un número de forma atemporal.
- Podemos asignar diferentes números en **diferentes instantes** de tiempo $X(t, w)$, donde $t \in T$.
- T: Conjunto de **parámetros del proceso** (usualmente instantes de tiempo).
- **Si fijamos el tiempo** t, al valor t_0: $X(t_0, w) = X(w)$ es una **variable aleatoria**.
- **Si fijamos el evento** w, al valor w_0: $X(t, w_0) = X(t)$ es una **función real sobre el tiempo**.

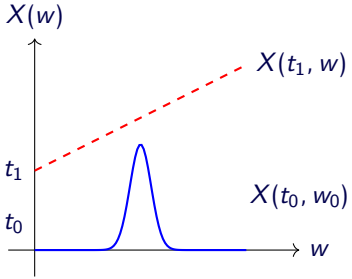

Gráfica de $X(w)$ para dos instantes temporales

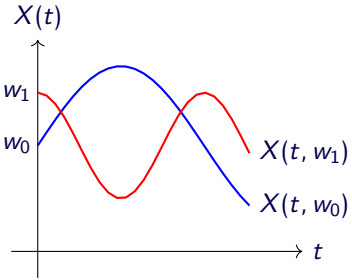

Gráfica de $X(t)$ para dos eventos

Proceso Estocástico

Definición (Proceso Estocástico)

Un **proceso estocástico** (PE) es una familia de variables aleatorias $\{X(t) = X_t \mid t \in T \subseteq \mathbb{R}\}$ indexadas por un conjunto T.

- T es un **conjunto de índices** que puede representar el tiempo (como $\mathbb{R}_+$ o $\mathbb{N}$) o cualquier otro parámetro de interés.
- X_t es una **variable aleatoria** para cada $t \in T$.
- Cada variable está definida sobre un **espacio de probabilidad** $(\Omega, \mathbb{B}, \mathbb{P})$, está compuesto por:
  - Ω: El **espacio muestral**, que es el conjunto de todos los posibles resultados del experimento.
  - $\mathbb{B}$: Una **σ-álgebra** sobre Ω, que es una colección de subconjuntos de Ω sobre los cuales se pueden definir probabilidades.
  - $\mathbb{P}$: Una **medida de probabilidad** en $\mathbb{B}$, que asigna probabilidades a los eventos en $\mathcal{F}$.
- Los valores de $X(t, w)$ se llaman **estados**.
  - El conjunto de valores constituye el **espacio de estados**, S.
- Un Proceso Estocástico estará descrito por sus **Funciones de Distribución** (de todo tipo).
  - Como X_t es un v.a. para cada t, tiene sentido hablar de $F(x_i, t_i) = F(x_i) = P(X(t_i) \leq x_i)$ para cualquier $t_i \in T$ arbitrario.
  - Así, podemos tener n funciones: $F(x_1)$, $F(x_2)$, ..., $F(x_n)$ para $0 \leq t_1 < t_2 < \cdots < t_n$.
  - Pero también tiene sentido hablar de **distribuciones conjuntas** $F(x_1, x_2, \ldots, x_n)$.

Ejemplos

1. Lanzamiento de un dado ($T = \mathbb{Z}^+$)
   - $\Omega = \{1, 2, 3, 4, 5, 6\}$
   - $S = \{\text{par, impar}\}$
2. Temperatura diaria ($T = \mathbb{Z}^+$)
   - $\Omega = \{\text{Todos los posibles registros de temperatura para cada día del año}\}$
   - $S = \{\text{frío, templado, caluroso}\}$
3. Precio de una acción ($T = \mathbb{R}^+$)
   - $\Omega = \{\text{Todos los posibles precios de la acción (valores reales positivos)}\}$
   - $S = \{\text{subió, bajó, se mantuvo}\}$
4. Distancia entre 2 puntos en movimiento en un espacio bidimensional. ($T = \mathbb{R}^+$)
   - $\Omega = \{(x_1, y_1, x_2, y_2) | (x_1, y_1) \in \mathbb{R}^2, (x_2, y_2) \in \mathbb{R}^2\}$
   - $S = \{d | d \in [0, \infty)\}$ con $d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$
5. Piso en el que está un ascensor ($T = \mathbb{Z}^+$)
   - $\Omega = \{(\textit{piso}, \textit{dirección}) | \textit{piso} \in \{1, 2, \ldots, N\}, \textit{dirección} \in \{\textit{arriba}, \textit{abajo}, \textit{parado}\}\}$
   - $S = \{1, 2, \ldots, N\}$

Espacio Muestral vs Espacio de Estados
Secuencias de Eventos

En los ejemplos mostrados anteriormente se ha considerado que los elementos del espacio muestral son valores; pero pueden estar formados por secuencias de valores.

Ejemplos

- **Proceso de Bernoulli** modela situaciones donde obtenemos uno de dos posibles resultados con una probabilidad fija para cada resultado.
  - Espacio de estados: $S = \{0, 1\}$.
  - Espacio muestral: $\Omega = \{$Todas las posibles secuencias de 0 y $1\}$
    Ejemplo: $\Omega = \{(0, 1, 0, 1, \ldots), (1, 1, 0, 0, \ldots), \ldots\ldots\}$
    - Ejemplos de Procesos de Bernoulli: **Inspección de Calidad** (determinar si cada artículo producido pasa o no). **Resultados de Exámenes Médicos** (seguimiento de resultados médicos repetidas para una enfermedad). **Resultados de Llamadas Telefónicas** (determinar si una llamada telefónica termina en venta), etc ...
- **Proceso de Poisson** modela el nº de eventos en un intervalo de tiempo fijo $[0, T]$.
  - Espacio de estados: $S = \mathbb{N}_0 = \{0, 1, 2, \ldots\}$. Un valor representa el número de eventos.
  - Espacio muestral: $\Omega = \{$Todas las posibles secuencias en $[0, T]\}$
    Ejemplo: $\Omega = \{(1), (4), \ldots, \underbrace{\ldots, (1, 3, 2), (0, 3, 1), \ldots}_{\text{Se hacen 3 lecturas}}, (1, 4, 2, 2), \ldots\}$
    - Ejemplos de Procesos de Poisson: **Número de llamadas** que llegan a un central en un minuto, **número de clientes** por hora en una tienda, **número de fallos** de internet cada 15', **emisiones (nº) de partícula** en física nuclear, etc ...

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Clasificación de los Procesos Estocásticos

Los procesos estocásticos se clasifican de acuerdo a sus dos parámetros:

- **Desde la perspectiva de T:**
  - Si T es un **intervalo de números reales** (t toma valores continuos), el proceso estocástico se llama **de tiempo continuo**.
  - Si T es un conjunto **numerable** (y por tanto discreto), el proceso estocástico se llama **de tiempo discreto** o **secuencia aleatoria**. Se suele denotar $\{X[n] : n = 1, 2, \ldots\}$.
- **Desde la perspectiva del conjunto de estados S:**
  - Si S es **continuo**, el proceso estocástico se llama **de estados continuos**.
  - Si S es **discreto**, el proceso se llama **de estados discretos**.

	X **Discreto**	X **Continua**
t **Discreto**	Proceso de estados discretos y tiempo discreto (**Cadena**)	Proceso de estados continuos y tiempo discreto
t **Continuo**	Proceso de estados discretos y tiempo continuo (**Proc. Saltos Puros**)	Proceso de estados continuos y tiempo continuo (**Proceso Continuo**)

Con más detalle ..

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Procesos de Markov

- Un proceso estocástico se llama **Proceso de Markov de primer orden** si:

$$
\begin{aligned}
P(X(t_{n+1}) = x_{n+1} | X(t_n) = x_n, \ldots, X(t_1) = x_1) &= P(X(t_{n+1}) = x_{n+1} | X(t_n) = x_n) \\
P(\ X(t_{n+1}) \in A\ \ | X(t_n) = x_n, \ldots, X(t_1) = x_1) &= P(\ X(t_{n+1}) \in A\ \ | X(t_n) = x_n)
\end{aligned}
$$

  - **Propiedad de Markov:** dado el estado presente, el estado futuro es independiente del pasado.

- Un proceso estocástico se llama **Proceso de Markov de segundo orden** si:

$$
\begin{aligned}
P(X(t_{n+1}) = x_{n+1} | X(t_n) = x_n, \ldots, X(t_1) = x_1) &= P(X(t_{n+1}) = x_{n+1} | X(t_n) = x_n, X(t_{n-1}) = x_{n-1}) \\
P(\ X(t_{n+1}) \in A\ \ | X(t_n) = x_n, \ldots, X(t_1) = x_1) &= P(\ X(t_{n+1}) \in A\ \ | X(t_n) = x_n, X(t_{n-1}) = x_{n-1})
\end{aligned}
$$

- Y así sucesivamente ...

Clasificación de Procesos de Markov
Con algún ejemplo

Clasificación de Procesos de Markov

- Desde la perspectiva del tiempo:
  - Proceso de Markov de tiempo continuo vs de tiempo discreto.
- Desde la perspectiva de los estados:
  - Proceso de Markov de espacio de estados continuo vs de estados discreto.

Tipos de procesos de Markov según el tiempo y el espacio de estados:

	Espacio de Estados, X, Discreto	**Espacio de Estados, X, Continuo**
Tiempo Discreto	Cadenas de Markov	Procesos de Markov de estados continuos
Tiempo Continuo	Proceso de Markov de tiempo continuo y estados discretos	Procesos de Markov continuo

- Salvo para la cadena de Markov, se suele especificar el tiempo de estados y de tiempo.

Ejemplos de cada tipo de proceso de Markov:

	Espacio de Estados, X, Discreto	**Espacio de Estados, X, Continuo**
Tiempo Discreto	Lanzamiento de moneda	Cantidad de lluvia caída cada mes
Tiempo Continuo	Número de clientes en la cola del supermercado	Velocidad del viento

Con más detalle ..

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Cadenas de Markov

- **Proceso de Markov**: **proceso estocástico** $\{X_t\}_{t\in T}$, que es **observable**, sin **acciones** y que verifica la **Propiedad de Markov** (dado el estado presente, el estado futuro es independiente del pasado).
- **Cadena de Markov:** Proceso de Márkov tiene un **espacio de estados discreto** (numerable).
- **Cadena de Markov en tiempos discretos**, $t \in \mathbb{N}$

$$p_{ijn} = P\Big(X_n = s_j | X_{n-1} = s_i, \ldots, X_2 = s_2, X_1 = s_1\Big) = P\Big(X_n = s_j | X_{n-1} = s_i\Big)$$

  - **Cadena Homogénea:** $p_{ijn} = p_{ij}$, es decir: $P\Big(X_n = s_j | X_{n-1} = s_i\Big) = P\Big(X_1 = s_j | X_0 = s_i\Big)\ \forall n, s_i, s_j$.
  - **Ecuaciones de Chapma-Kolmogorov:** Si $p_{ij}(n) := P(X_n = s_j | X_0 = s_i)$, $P(n) = P^n = (\!(p_{ij})\!)^n$ entonces:

$$\forall\ 0 < r < n \quad p_{ij}(n) = \sum_k p_{ik}(r)p_{kj}(n-r) \qquad P(n+m) = P^{n+m} = P^n P^m = P(n)P(m).$$

- **Cadena de Markov en tiempos continuos**, $t \in \mathbb{R}$

Para cada $t, t' \geq 0$ y los correspondientes estados $s_i, s_j, \{s_{ku} |\ 0 \leq u \leq t'\}$ se cumple:

$$p_{ij}(t', t'+t) = P\Big(X(t+t') = s_j | X(t') = s_i, X(u) = s_{k_u}, 0 \leq u \leq t'\Big) = P\Big(X(t+t') = s_j | X(t') = s_i\Big)$$

  - **Cadena homogénea:** $p_{ij}(t', t'+t) = p_{ij}(0, 0+t) = p_{ij}(t)$, es decir:

$$p_{ij}(t) = P(X(t'+t) = s_j | X(t') = s_i) = P(X(t) = s_j | X(0) = s_i)\ \forall s_i, s_j \in S, t \geq 0$$

  - **Ecuaciones de Chapman-Kolmogorov:** Si $p_{ij}(t+s) = P\Big(X(t+s) = s_j | X(t) = s_i\Big)$

$$p_{ij}(t+s) = \sum_k p_{ik}(t)p_{kj}(s); \forall s, t > 0 \qquad \text{Si } P(t) = \Big(\!\Big(p_{ij}(t)\Big)\!\Big) \Rightarrow P(t+s) = P(t)P(s).$$

Desarrollo

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

La Interfaz Agente–Entorno

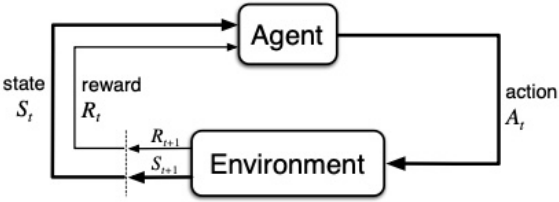

- El agente y el entorno interactúa en una serie de **pasos** $t = 0, 1, 2, 3, \ldots$.
- En cada paso t:
  - El agente recibe alguna representación del entorno (**estado**), $S_t \in \mathcal{S}$
  - El agente realiza una **acción** $A_t \in \mathcal{A}(s)$
- En cada paso $t + 1$, como consecuencia de la acción:
  - El agente recibe una señal numérica (**recompensa**), $R_{t+1} \in \mathcal{R} \subset \mathbb{R}$
  - El entono se encuentra en un **nuevo estado** S_{t+1}
- **Secuencia/Trayectoria**: $\mathcal{H} \doteq S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \ldots$
- Modelado: **PDM finito con recompensas**: $\mathcal{S}$, $\mathcal{A}$ y $\mathcal{R}$ tiene un número finito de elemento.

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Estados de Markov en RL
Matriz de Transición de Estados

- Definición formal. **Cadena de Markov en tiempos discretos**, $t \in \mathbb{N}$

$$p_{ijn} = P\Big(X_n = s_j | X_{n-1} = s_i, \ldots, X_2 = s_2, X_1 = s_1\Big) = P\Big(X_n = s_j | X_{n-1} = s_i\Big)$$

- **Adaptamos a la notación del Aprendizaje por Refuerzo.**
  - Un estado S_t es Markov si y solo si: $Pr[S_{t+1} \mid S_t] = P[S_{t+1} \mid S_1, \ldots, S_{t-1}, S_t]$
    - El estado captura toda la información relevante de la historia.
    - Una vez conocido el estado, se puede descartar la historia.
- Para un estado de Markov s y un estado sucesor s', la **probabilidad de transición** de estado se define por:

$$p(s'|s) = P_{ss'} = Pr[S_{t+1} = s' | S_t = s]$$

- La **matriz de transición de estados** $\mathbf{P}$ define las probabilidades de transición de todos los estados s a todos los estados sucesores s':

$$\mathbf{P} = \begin{bmatrix} P_{11} & \cdots & P_{1n} \\ \vdots & \ddots & \vdots \\ P_{n1} & \cdots & P_{nn} \end{bmatrix}$$

  - P_{ij} la probabilidad de transición partiendo del estado i para llegar al estado j.
  - Donde cada fila de la matriz suma 1.

Proceso (Cadena) de Markov
Episodios

Definición (Proceso de Markov)

Un proceso de Markov es un proceso aleatorio sin memoria, es decir, una secuencia de estados aleatorios $S_1, S_2, \ldots$ con la propiedad de Markov.

Definición (Proceso de Markov)

Un **Proceso de Markov** (o Cadena de Markov) es un par $\langle \mathcal{S}, \mathbf{P} \rangle$, donde:

- $\mathcal{S}$ es un conjunto (finito) de estados.
- $\mathbf{P}$ es una matriz de probabilidad de transición de estados, $p(s'|s) = P_{ss'} = P[S_{t+1} = s'|S_t = s]$.

Definición (Trayectoria/Episodio)

- Una **trayectoria** o historia de estados es una secuencia de estados.
- Un **episodio** de estados es una historia que empieza en un estado inicial y finaliza es un estado terminal.
  - Un episodio es una muestra.
  - Número de pasos: T es una v.a. que depende del episodio.

Ejemplo: Cadena de Markov del Estudiante

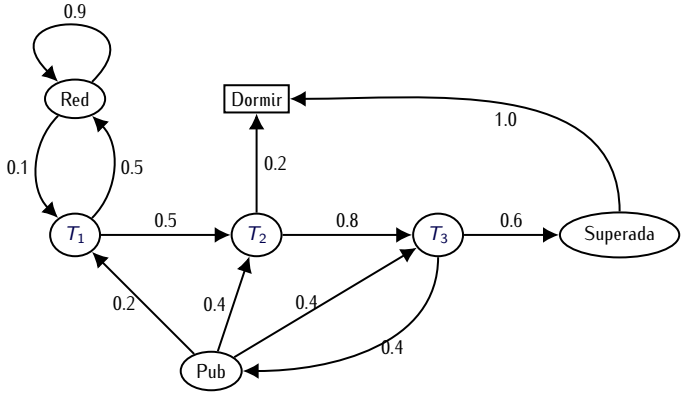

Episodios:

- T_1 T_2 T_3 Superada Dormir
- T_1 Red Red T_1 T_2 Dormir
- T_1 T_2 T_3 Pub T_2 T_3 Superada Dormir
- T_1 Red Red T_1 T_2 T_3 Pub T_1 Red Red Red T_1 T_2 T_3 Pub T_2 Dormir

$$
\mathbf{P} = \begin{array}{c} \\ T_1 \\ T_2 \\ T_3 \\ \text{Superada} \\ \text{Pub} \\ \text{Red} \\ \text{Dormir} \end{array}
\begin{array}{c}
\begin{array}{ccccccc} T_1 & T_2 & T_3 & \text{Superada} & \text{Pub} & \text{Red} & \text{Dormir} \end{array} \\
\begin{bmatrix}
 & 0{,}5 & & & & 0{,}5 & \\
 & & 0{,}8 & & & & 0{,}2 \\
 & & & 0{,}6 & 0{,}4 & & \\
 & & & & & & 1 \\
0{,}2 & 0{,}4 & 0{,}4 & & & & \\
0{,}1 & & & & & 0{,}9 & \\
 & & & & & & 1
\end{bmatrix}
\end{array}
$$

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Proceso de Recompensa de Markov (MRP)

Definición (**Proceso de Recompensa de Markov**)

Un MRP es un conjunto $\langle \mathcal{S}, \mathbf{P}, \mathcal{R}, \gamma \rangle$, donde:

- $\mathcal{S}$: Conjunto finito de estados.
- $\mathbf{P} = (\!(p_{ss'})\!)$: Matriz de transición de estados.
- $\mathcal{R} = \{R_s | s \in \mathcal{S}\} \subset \mathbb{R}$: Recompensas finitas $R_s = r(s) = \mathbb{E}[R_{t+1} \mid S_t = s]$.
- γ: Factor de descuento ($\gamma \in [0, 1]$).

Definición (**Trayectoria/Episodio**)

- Una **trayectoria** o historia de estados es una secuencia de estados y recompensas.
$$S_0, R_1, S_1, R_2, S_2, \ldots$$
- Un **episodio** es una historia que empieza en un estado inicial y finaliza en la recompensa del estado terminal
$$S_0, R_1, S_1, R_2, S_2, \ldots, S_T, R_T$$

- Ejemplo: MRP del Estudiante

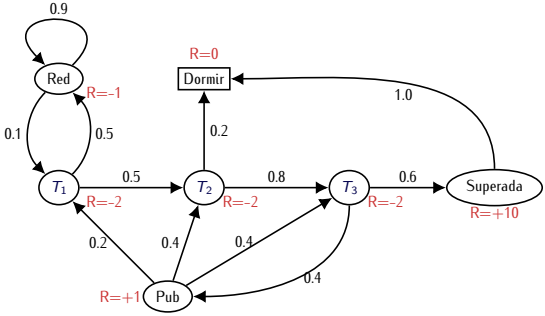

- $R_{T_1} = r_{T_2} = r_{T_3} = -2$
- $R_{Red} = -1$
- $R_{Pub} = +1$
- $R_{Superada} = +10$
- $R_{Dormir} = 0$

Recompensas y Retornos

- **Recompensa Inmediata:** R_s, $R_t = R(S_t)$
- **Función de recompensa:** $r(s) = \mathbb{E}[R_{t+1}|S_t = s]$
  - Para $t = 0$, $r(s) = \mathbb{E}[R_1|S_t = s]$
  - Si entendemos que no se empieza en un estado concreto: $r(s) = R_s$
  - Si se interpreta como la recompensa esperad al salir del estado s: $r(s) = \sum_{s'} r_{s'} P_{ss'}$
- **Retorno** después del paso t: $G_t = R_{t+1} + R_{t+2} + R_{t+3} + \cdots + R_T = \sum_{k=t+1}^{T} R_k$
- **Retorno con descuento** después del paso t:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots + \gamma^{T-t-1} R_T = \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k \textbf{ para } \gamma \in [0, 1].$$

  - Motivos para **usar** un descuento:
    - Representa la preferencia natural por recompensas inmediatas
    - Refleja la incertidumbre del futuro
    - Conveniencia matemática
    - Evita retornos infinitos
  - Motivos para **no usar** un descuento ($\gamma = 1$):
    - Todas las trayectorias llevan a un estado terminal

Definición (Esperanza / Expectativa / Valor esperado)

Dada una variable aleatoria X:

- Caso discreto. Dada $P[X = x]$, se define como $\mathbb{E}[X] = \sum_x x\,\mathrm{P}[X = x]$
- Caso continuo. Dada $f_X(x)$, se define como $\mathbb{E}[X] = \int_{\mathbb{X}} x \cdot f_X(x)dx$.

Definición (Esperanza Condicional (dado un valor))

Dadas dos variables aleatorias X e Y:

- Caso discreto. Dadas $P[X = x|Y = y]$, se define como $\mathbb{E}[X|Y = y] = \sum_x x\,\mathrm{P}[X = x|Y = y]$
- Caso continuo. Dadas $f_{X|Y}(x|y)$, se define como $\mathbb{E}[X|Y = y] = \int_{\mathbb{X}} x \cdot f_{X|Y}(x|Y = y)dx$.

$\mathbb{E}[X]$ es un número pero $\mathbb{E}[X|Y]$ es una variable aleatoria

Expectativa Iterada

Teorema (Expectativas Iteradas / Propiedad de las torres / Ley de la expectativa total)

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X \mid Y]]$$

- X *es una variable aleatoria.*
- Y *es una variable aleatoria* ***que afecta a la distribución de*** X.

Demostración.

$$\begin{aligned}\mathbb{E}_x[X] &= \sum_x xP(X = x) = \sum_y \sum_x xP(X = x \mid Y = y)P(Y = y) \\ &= \sum_y \mathbb{E}_{x|y}[X \mid Y = y]P(Y = y) = \mathbb{E}_y[\mathbb{E}_{x|y}[X \mid Y]]\end{aligned}$$

□

Ejemplo (El retorno G_t a partir de un estado S_t)

Si $X = G_t$, $Y = S_t$ influye en G_t, entonces: $\mathbb{E}[G_t] = \mathbb{E}[X] = \mathbb{E}[\,\mathbb{E}[X \mid Y]\,] = \mathbb{E}[\,\mathbb{E}[G_t \mid S_t]\,] \quad \forall t$

Función Valor

Definición (Función Valor)

Función valor de un estado, $v(s)$, de un proceso de recompensas de Markov, se define como:

$$v(s) = \mathbb{E}[G_t \mid S_t = s] \text{ con } G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

Ecuaciones de Bellman

$$v(s) = \mathbb{E}[R_{t+1} + \gamma v(S_{t+1}) \mid S_t = s]$$

Demostración.

$$\begin{aligned}
v(s) &= \mathbb{E}[G_t \mid S_t = s] = \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots \mid S_t = s] \\
&= \mathbb{E}[R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \ldots) \mid S_t = s] = \mathbb{E}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\
&= \mathbb{E}[R_{t+1} \mid S_t = s] + \gamma \mathbb{E}[G_{t+1} \mid S_t = s] = \mathbb{E}[R_{t+1} \mid S_t = s] + \gamma \mathbb{E}[\mathbb{E}[G_{t+1} | S_{t+1}] \mid S_t = s] \\
&= \mathbb{E}[R_{t+1} \mid S_t = s] + \gamma \mathbb{E}[v(S_{t+1}) \mid S_t = s] \\
&= \mathbb{E}[R_{t+1} + \gamma \cdot v(S_{t+1}) \mid S_t = s]
\end{aligned}$$

$\mathbb{E}[G_t] = \mathbb{E}[\mathbb{E}[G_t \mid S_t]] \forall t$

□

Resolución de las Ecuaciones de Bellman

Ecuaciones de Bellman

$$v(s) = \mathbb{E}[R_{t+1} + \gamma v(S_{t+1}) \mid S_t = s]$$

- La función de valor **se puede descomponer en dos partes**:
  - Recompensa inmediata: $\mathbb{E}[R_{t+1}|S_t = s] = R_s$
  - Valor descontado del estado sucesor: $\gamma\mathbb{E}[v(S_{t+1})|S_t = s] = \gamma \sum_{s'} P_{ss'} v(s')$
- **Nueva expresión:** $v(s) = R_s + \gamma \sum_{s'} P_{ss'} v(s')$
- **Forma matricial:** $\mathbf{v} = \mathbf{R} + \gamma\mathbf{P} \cdot \mathbf{v}$ ¡¡ Responde a una ecuación lineal !!
- **Solución directa:** $\mathbf{v} = \mathbf{R} + \gamma\mathbf{P} \cdot \mathbf{v} \Rightarrow \mathbf{I}\mathbf{v} = \mathbf{R} + \gamma\mathbf{P} \cdot \mathbf{v} \Rightarrow (\mathbf{I} - \gamma\mathbf{P})\mathbf{v} = \mathbf{R} \Rightarrow$

$$\boxed{\mathbf{v} = (\mathbf{I} - \gamma\mathbf{P})^{-1}\mathbf{R}}$$

  - Complejidad computacional $O(n^3)$ para n estados.
  - No es la mejor solución. Hay métodos alternativos.

Ejemplo: Cadena de Recompensas de Markov del Estudiante
Retornos Descontados para un Episodio

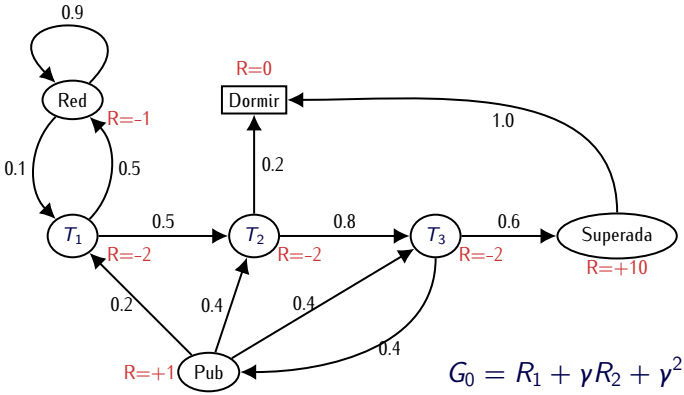

$$G_0 = R_1 + \gamma R_2 + \gamma^2 R_3 + \ldots \gamma^{T+1} R_T$$

- $R_{T_1} = r_{T_2} = r_{T_3} = -2$
- $R_{Red} = -1$
- $R_{Pub} = +1$
- $R_{Superada} = +10$
- $R_{Dormir} = 0$

Para $\gamma = 1/2$, algunos retornos empezando en T_1:

- T_1 T_2 T_3 Superada Dormir
  $G_0 = -2 - 2 \cdot \frac{1}{2} - 2 \cdot \frac{1}{4} + 10 \cdot \frac{1}{8} = -2{,}25$
- T_1 Red Red T_1 T_2 Dormir
  $G_0 = -2 - 1 \cdot \frac{1}{2} - 2 \cdot \frac{1}{4} - 1 \cdot \frac{1}{8} - 2 \cdot \frac{1}{16} = -3{,}125$

Ejemplo: Cadena de Recompensas de Markov del Estudiante
Función de evaluación: Ecuaciones de Bellman

$$v(s) = \mathbb{E}[G_T | S_t = s] = \mathbb{E}[R_{t+1} + \gamma v(S_{t+1}) \mid S_t = s] = R_s + \gamma \sum_{s'} P_{ss'} v(s')$$

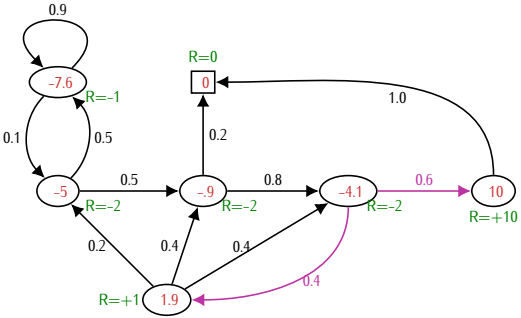

$$v(T_1) = -2 + 0{,}9 \times (0{,}5 \cdot v(T_2) + 0{,}5 \cdot v(\text{Red}))$$
$$v(T_2) = -2 + 0{,}9 \times (0{,}8 \cdot v(T_3) + 0{,}2 \cdot v(\text{Dormir}))$$
$$v(T_3) = -2 + 0{,}9 \times (\ 0{,}6 \cdot v(\text{Superada}) + 0{,}4 \cdot v(\text{Pub}))$$
$$v(\text{Red}) = -1 + 0{,}9 \times (0{,}1 \cdot v(T_1) + 0{,}9 \cdot v(\text{Red}))$$
$$v(\text{Pub}) = 1 + 0{,}9 \times (0{,}2 \cdot v(T_1) + 0{,}4 \cdot v(T_2) + 0{,}4 \cdot v(T_3))$$
$$v(\text{Superada}) = 10 + 0{,}9 \times v(\text{Dormir})$$
$$v(\text{Dormir}) = 0$$

- A partir de $v(\text{Dormir}) = 0$ calculamos $v(\text{Superada}) = 10$
- Y así vamos sustituyendo hasta resolver el sistema de ecuaciones.

Ejemplo: Cadena de Recompensas de Markov del Estudiante

Función de evaluación: Ecuaciones de Bellman con Resolución Matricial

$$v(s) = R_s + \gamma \sum_{s'} P_{ss'} v(s') \quad \Rightarrow \quad \mathbf{v} = \mathbf{R} + \gamma \mathbf{P} \cdot \mathbf{v} \quad \Rightarrow \quad \boxed{\mathbf{v} = (\mathbf{I} - \gamma \mathbf{P})^{-1} \mathbf{R}}$$

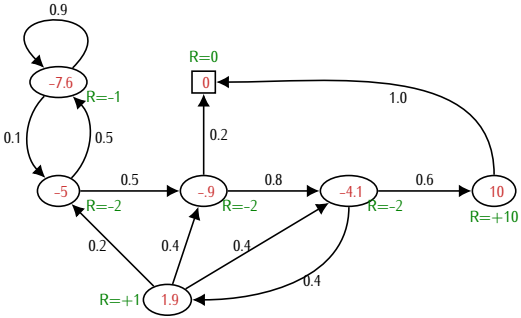

$$\begin{bmatrix} v(T_1) \\ v(T_2) \\ v(T_3) \\ v(\text{Red}) \\ v(\text{Pub}) \\ v(\text{Superada}) \\ v(\text{Dormir}) \end{bmatrix} = \left(\mathbf{I} - \gamma \begin{bmatrix} 0 & 0{,}5 & 0 & 0{,}5 & 0 & 0 & 0 \\ 0 & 0 & 0{,}8 & 0 & 0 & 0 & 0{,}2 \\ 0 & 0 & 0 & 0 & 0{,}4 & 0{,}6 & 0 \\ 0{,}1 & 0 & 0 & 0{,}9 & 0 & 0 & 0 \\ 0{,}2 & 0{,}4 & 0{,}4 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \right)^{-1} \cdot \begin{bmatrix} -2 \\ -2 \\ -2 \\ -1 \\ 1 \\ 10 \\ 0 \end{bmatrix}$$

$$\begin{bmatrix} v(T_1) \\ v(T_2) \\ v(T_3) \\ v(\text{Red}) \\ v(\text{Pub}) \\ v(\text{Superada}) \\ v(\text{Dormir}) \end{bmatrix} = \left(\begin{bmatrix} 1{,}316 & 0{,}663 & 0{,}549 & 3{,}117 & 0{,}198 & 0{,}296 & 0{,}386 \\ 0{,}079 & 1{,}160 & 0{,}959 & 0{,}187 & 0{,}345 & 0{,}518 & 0{,}675 \\ 0{,}110 & 0{,}222 & 1{,}333 & 0{,}260 & 0{,}480 & 0{,}720 & 0{,}688 \\ 0{,}623 & 0{,}314 & 0{,}260 & 6{,}740 & 0{,}094 & 0{,}140 & 0{,}183 \\ 0{,}305 & 0{,}617 & 0{,}924 & 0{,}722 & 1{,}333 & 0{,}499 & 0{,}560 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0{,}9 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \right) \cdot \begin{bmatrix} -2 \\ -2 \\ -2 \\ -1 \\ 1 \\ 10 \\ 0 \end{bmatrix}$$

$$\mathbf{v} = \begin{bmatrix} v(T_1) \\ v(T_2) \\ v(T_3) \\ v(\text{Red}) \\ v(\text{Pub}) \\ v(\text{Superada}) \\ v(\text{Dormir}) \end{bmatrix} = \begin{bmatrix} -5{,}01 \\ 0{,}94 \\ 4{,}08 \\ -7{,}63 \\ 1{,}90 \\ 10{,}0 \\ 0 \end{bmatrix} \qquad \text{para } \gamma = 0{,}9$$

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Procesos de Decisión de Markov (MDP)

Definición (**Proceso de Decisión de Markov**)

Un MDP es un conjunto $\langle \mathcal{S}, \mathcal{A}, \{\mathbf{P}^a\}_a, \mathcal{R}, \gamma \rangle$, con:

- $\mathcal{S}$: Conjunto finito de estados.
- $\mathcal{A}$: Conjunto finito de acciones.
- $\mathbf{P}^a$: Matriz de transición de estados:
  $P^a_{ss'} = P(S_{t+1} = s' \mid S_t = s, A_t = a)$
- $\mathcal{R}$: Función de recompensa:
  $R^a_s = r(s, a) = \mathbb{E}[R_{t+1} \mid S_t = s, A_t = a]$
- γ: Factor de descuento ($\gamma \in [0, 1]$).

Definición (**Trayectoria/Episodio**)

- Una trayectoria o historia de estados es una secuencia de estados, acciones y recompensas.
  $S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3 \ldots$

Ejemplo: MDP del Estudiante

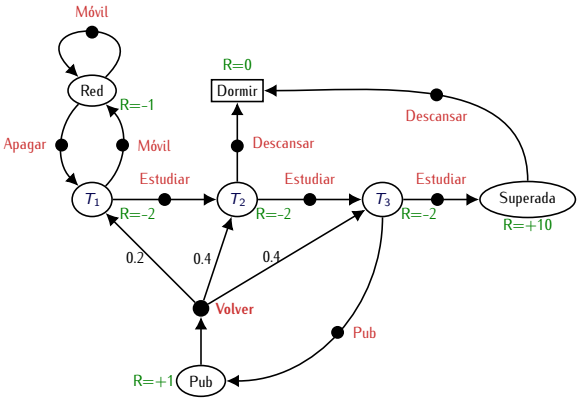

- Se cambian algunas las probabilidades por acciones concretas.
- Solo se ha dejado aleatoriedad en la acción Volver.
- Se podría hacer dejado aleatoriedad en cualquier estado del que salga más de 1 flecha.

Políticas

- Una **política** π es una **distribución sobre acciones** dadas las condiciones del estado:
$$\pi(a \mid s) = P(A_t = a \mid S_t = s)$$
Un ejemplo de política, donde existen 3 posibles acciones para un estado es: $\pi(a|s) = \begin{cases} 0{,}3 & \text{si } a = a_1 \\ 0{,}2 & \text{si } a = a_2 \\ 0{,}5 & \text{si } a = a_3 \end{cases}$
- Las políticas en los MDPs:
  - Dependientes del estado actual (**Markovianas**): $\pi(a|s) = P(A_t = a|H_t)$
  - Independientes del tiempo (**estacionarias**): $\pi_t(a \mid s) = \pi(a \mid s) \quad \forall t$. (Si se prefiere, para $t > 0$, $A_t \sim \pi(\cdot \mid S_t)$
  - Si siempre se toma la misma decisión (**determinística**): $\pi(s)$
- Dada una política en un Proceso de **Decisión** de Markov $\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathbf{P}, \mathcal{R}, \gamma \rangle$ genera trayectorias $S_0, A_0, R_1, S_1, \ldots$ Entonces, podemos definir:
  - Un proceso de **recompensa** de Markov $\langle \mathcal{S}, \mathbf{P}^\pi, \mathcal{R}^\pi, \gamma \rangle$ (quitando acciones)
    - Genera la secuencia de estados y recompensas $S_0, R_1, S_1, \ldots$
  - Un **proceso** de Markov $\langle \mathcal{S}, \mathbf{P}^\pi \rangle$ (quitando recompensas)
    - Genera la secuencia de estados $S_0, S_1, \ldots$
  - Donde: $P^\pi_{s,s'} = \sum_{a \in \mathcal{A}} \pi(a \mid s) P^a_{s,s'} \qquad R^\pi_s = \sum_{a \in \mathcal{A}} \pi(a \mid s) R^a_s$

Ejemplo de PM y PRM a partir de un PDM

- Proceso de Decisión de Markov con 2 acciones, 2 estados y 4 recompensas.
  - Matriz de la políticas: $\pi(a|s) = \begin{bmatrix} \pi(a_1|s_1) & \pi(a_2|s_1) \\ \pi(a_1|s_2) & \pi(a_2|s_2) \end{bmatrix} = \begin{bmatrix} 0{,}7 & 0{,}3 \\ 0{,}4 & 0{,}6 \end{bmatrix}$
  - Matriz de transición (2 acciones): $P(s'|s, a_1) = \begin{bmatrix} P(s_1|s_1, a_1) & P(s_2|s_1, a_1) \\ P(s_1|s_2, a_1) & P(s_2|s_2, a_1) \end{bmatrix} = \begin{bmatrix} 0{,}5 & 0{,}5 \\ 0{,}6 & 0{,}4 \end{bmatrix}$

    $P(s'|s, a_2) = \begin{bmatrix} P(s_1|s_1, a_2) & P(s_2|s_1, a_2) \\ P(s_1|s_2, a_2) & P(s_2|s_2, a_2) \end{bmatrix} = \begin{bmatrix} 0{,}2 & 0{,}8 \\ 0{,}1 & 0{,}9 \end{bmatrix}$
  - Matriz de recompensas: $R(s, a) = \begin{bmatrix} R(s_1, a_1) & R(s_1, a_2) \\ R(s_2, a_1) & R(s_2, a_2) \end{bmatrix} = \begin{bmatrix} 10 & 5 \\ 2 & 8 \end{bmatrix}$
- Cálculo de $P^{\pi}_{s,s'} = \sum_{a \in \mathcal{A}} \pi(a \mid s) P(s' \mid s, a)$:
  - $P^{\pi}_{s_1,s_2} = \sum_{a \in \mathcal{A}} \pi(a|s_1) P(s_2|s_1, a)$
    - Para a_1: $\pi(a_1|s_1) = 0{,}7$, $P(s_2|s_1, a_1) = 0{,}5$.
    - Para a_2: $\pi(a_2|s_1) = 0{,}3$, $P(s_2|s_1, a_2) = 0{,}8$.
    - Por tanto, $P^{\pi}_{s_1,s_2} = (0{,}7)(0{,}5) + (0{,}3)(0{,}8) = 0{,}35 + 0{,}24 = 0{,}59$

$$\mathbf{P}^{\pi} = \begin{bmatrix} P^{\pi}_{s_1,s_1} & P^{\pi}_{s_1,s_2} \\ P^{\pi}_{s_2,s_1} & P^{\pi}_{s_2,s_2} \end{bmatrix} = \begin{bmatrix} 0{,}41 & 0{,}59 \\ 0{,}3 & 0{,}7 \end{bmatrix}$$

- Cálculo de $R^{\pi}_{s} = \sum_{a \in \mathcal{A}} \pi(a \mid s) r(s, a)$
  - $R^{\pi}_{s_1} = \sum_{a \in \mathcal{A}} \pi(a|s_1) R(s_1, a)$
    - Para a_1: $\pi(a_1|s_1) = 0{,}7$, $R(s_1, a_1) = 10$.
    - Para a_2: $\pi(a_2|s_1) = 0{,}3$, $R(s_1, a_2) = 5$.
    - Por tanto, $R^{\pi}_{s_1} = (0{,}7)(10) + (0{,}3)(5) = 7 + 1{,}5 = 8{,}5$

$$\mathbf{R}^{\pi} = \begin{bmatrix} R^{\pi}_{s_1} \\ R^{\pi}_{s_2} \end{bmatrix} = \begin{bmatrix} 8{,}5 \\ 5{,}6 \end{bmatrix}$$

Función Valor en un MDP
Ecuaciones de Bellman

- La **función de valor de estado** $v_\pi(s)$ es el retorno esperado desde el estado s siguiendo la política π:

$$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\middle|\, S_t = s\right], \quad \text{para todo } s \in \mathcal{S},$$

  - **Ecuación de Bellman:** $v_\pi(s) = \mathbb{E}_\pi\left[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s\right]$

- La **función de valor estado-acción** $q_\pi(s, a)$ es el retorno esperado desde el estado s, tomando la acción a, y siguiendo la política π:

$$q_\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\middle|\, S_t = s, A_t = a\right], \quad \text{para todos } s \in \mathcal{S},\ a \in \mathcal{A}$$

  - **Ecuación de Bellman:** $q_\pi(s, a) = \mathbb{E}_\pi\left[R_{t+1} + \gamma q_\pi(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a\right]$

Diagramas de Respaldo

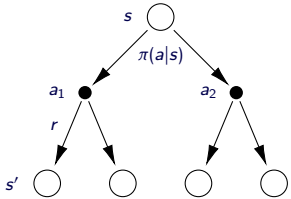

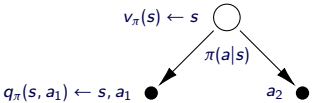

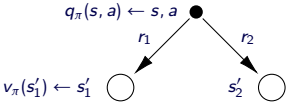

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a|s) q_\pi(a, s) \qquad q_\pi(s, a) = R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a v_\pi(s')$$

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a v_\pi(s') \right)$$

Cálculo de las Ecuación de Bellman

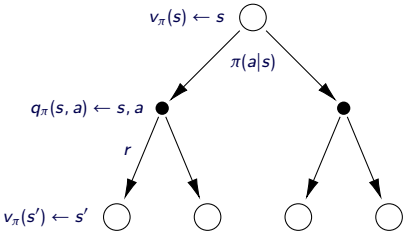

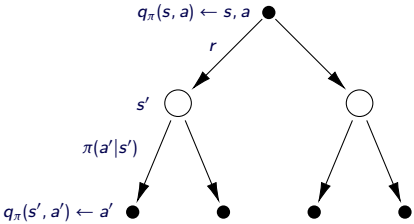

- Para la función valor del estado:

$$v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a v_\pi(s') \right)$$

- Para la función valor estado-acción:

$$q_\pi(s,a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \sum_{a' \in A} \pi(a' \mid s') q_\pi(s',a')$$

Resolución Matricial

- En un Proceso de **Recompensas** de Markov, con $P_{ss'}$:
  - $v(s) = R_s + \gamma \sum_{s'} P_{ss'} v(s')$
  - **Forma matricial:** $\mathbf{v} = \mathbf{R} + \gamma \mathbf{P} \cdot \mathbf{v}$
    - $\mathbf{v}$ vector columna con valores $v(s)$ para todos los estados.
    - $\mathbf{R}$ vector columna con las recompensas $r(s)$ para todos los estados.
    - $\mathbf{P} = ((p_{ss'}))$, con las probabilidades de transición $p_{ss'}$.
  - Solución: $\mathbf{v} = (\mathbf{I} - \gamma \mathbf{P})^{-1} \mathbf{R}$ (si invertible)
- En un Proceso de **Decisión** de Markov, con $P^a_{ss'}$:
  - $v_\pi(s) = \sum_{a \in \mathcal{A}} \pi(a|s) \left(R^a_s + \gamma \sum_{s' \in \mathcal{S}} P^a_{ss'} v_\pi(s') \right) = \sum_{a \in \mathcal{A}} \pi(a|s) R^a_s + \gamma \sum_{s' \in \mathcal{S}} \sum_{a \in \mathcal{A}} \pi(a|s) P^a_{ss'} v_\pi(s')$
  - **Forma matricial:** $\mathbf{v}_\pi = \mathbf{R}^\pi + \gamma \mathbf{P}^\pi \cdot \mathbf{v}_\pi$
    - $\mathbf{v}_\pi$ vector columna con $v_\pi(s)$ para todos los estados.
    - $\mathbf{R}^\pi$ vector columna con las recompensas esperadas $\bar{r}^\pi_s = \sum_{a \in \mathcal{A}} \pi(a|s) R^a_s$
    - $\mathbf{P}^\pi = ((\bar{p}^\pi_{ss'}))$ con las probabilidades esperadas $\bar{p}^\pi_{ss'} = \sum_{a \in \mathcal{A}} \pi(a|s) P^a_{ss'}$
  - Solución: $\mathbf{v} = (\mathbf{I} - \gamma \mathbf{P}^\pi)^{-1} \mathbf{R}^\pi$ (si invertible)

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

PDM con Recompensas Estocásticas
Sutton & Barto

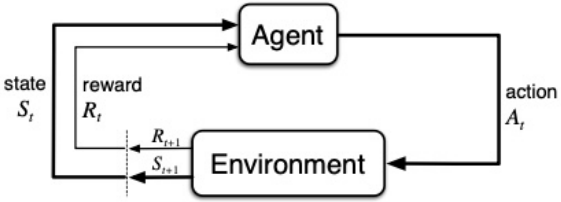

- **Trayectorias**: $S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, \ldots$
- **Transiciones**: Cambiamos $P^a_{ss'}$ por $P^{ar}_{ss'}$. R_t **es una v.a.**
  - $P^{ar}_{ss'}$: $p(s', r|s, a) \doteq \Pr\{S_t = s', R_t = r|S_{t-1} = s, A_{t-1} = a\}$ con $\sum_r \sum_{s'} p(s', r|s, a) = 1$
  - Podemos obtener $P^a_{ss'}$: $p(s'|s, a) \doteq \Pr\{S_t = s'|S_{t-1} = s, A_{t-1} = a\} = \sum_{r \in R} p(s', r|s, a)$.
- **Recompensas**:
  - $r(s, a) \doteq \mathbb{E}[R_t|S_{t-1} = s, A_{t-1} = a] = \sum_{r \in R} r \cdot p(r|s, a) = \sum_{r \in R} r \sum_{s' \in S} p(s', r|s, a) = \sum_{r \in R} r \sum_{s' \in S} P^{ar}_{ss'}$
  - $r(s, a, s') \doteq \mathbb{E}[R_t|S_{t-1} = s, A_{t-1} = a, S_t = s'] = \sum_{r \in R} r \cdot p(r|s, a, s') = \sum_{r \in R} r \frac{p(s', r|s, a)}{p(s'|s, a)} = \sum_{r \in R} r . \frac{P^{ar}_{ss'}}{P^a_{ss'}}$.

Función Valor en un MDP con Recompensas Estocásticas
Ecuaciones de Bellman

Función valor de estado:

$$v_\pi(s) \doteq \mathbb{E}_\pi[G_t \mid S_t = s] \overset{Bellman}{=} \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s]$$

Función valor estado-acción:

$$q_\pi(s,a) \doteq \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a] \overset{Bellman}{=} \mathbb{E}_\pi[R_{t+1} + \gamma q_\pi(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a]$$

Diagramas de Respaldo

$$v_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a|s) q_\pi(a,s) \qquad q_\pi(s,a) = \sum_{r\in\mathcal{R}} r \sum_{s'\in\mathcal{S}} P^{ar}_{ss'} + \gamma \sum_{r\in\mathcal{R}} \sum_{s'\in\mathcal{S}} P^{ar}_{ss'} v_\pi(s')$$

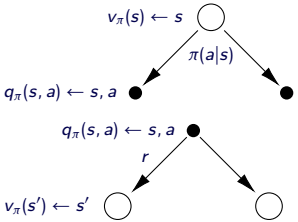

$$v_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a|s) \sum_{s',r} P^{ar}_{ss'} \left(r + \gamma v_\pi(s')\right)$$

$$q_\pi(s,a) = \sum_{s',r} r \cdot P^{ar}_{ss'} + \gamma \sum_{s',r} P^{ar}_{ss'} \sum_{a'\in\mathcal{A}} \pi(a' \mid s') q_\pi(s',a')$$

$$= \sum_{s',r} P^{ar}_{ss'} \left(r + \gamma \sum_{a'\in\mathcal{A}} \pi(a' \mid s') q_\pi(s',a') \right)$$

Resolución Matricial

- En un Proceso de Decisión de Markov, con $P^a_{ss'}$:
  - $v_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a|s) \left(R^a_s + \gamma \sum_{s'\in\mathcal{S}} P^a_{ss'} v_\pi(s') \right) = \sum_{a\in\mathcal{A}} \pi(a|s) R^a_s + \gamma \sum_{s'\in\mathcal{S}} \sum_{a\in\mathcal{A}} \pi(a|s) P^a_{ss'} v_\pi(s')$
  - Forma matricial: $\mathbf{v}_\pi = \mathbf{R}^\pi + \gamma \mathbf{P}^\pi \cdot \mathbf{v}_\pi$
    - $\mathbf{v}_\pi$ vector columna con $v_\pi(s)$ para todos los estados.
    - $\mathbf{R}^\pi$ vector columna con las recompensas inmediatas esperadas $\bar{r}^\pi_s = \sum_{a\in\mathcal{A}} \pi(a|s) R^a_s$
    - $\mathbf{P}^\pi = ((\bar{p}^\pi_{ss'}))$ con las probabilidades esperadas $\bar{p}^\pi_{ss'} = \sum_{a\in\mathcal{A}} \pi(a|s) P^a_{ss'}$
- $v_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a|s) \sum_{s',r} P^{ar}_{ss'} \left(R^a_s + \gamma v_\pi(s') \right) = \sum_{a\in\mathcal{A}} \pi(a|s) \sum_{s',r} P^{ar}_{ss'} R^a_s + \gamma \sum_{s'} \sum_{a\in\mathcal{A},r} \pi(a|s) P^{ar}_{ss'} v_\pi(s')$
  - Forma matricial: $\mathbf{v}_\pi = \mathbf{R}^\pi + \gamma \mathbf{P}^\pi \cdot \mathbf{v}_\pi$
    - $\mathbf{v}_\pi$ vector columna con $v_\pi(s)$ para todos los estados.
    - $\mathbf{R}^\pi$ vector columna con las recompensas inmediatas esperadas $R^\pi_s = \sum_{a\in\mathcal{A}} \pi(a|s) \sum_{s',r} P^{ar}_{ss'} R^a_s = \sum_r p(r|s) R^a_s$
    - $\mathbf{P}^\pi = ((\bar{p}^\pi_{ss'})$ con las probabilidades esperadas de la transición $\bar{p}^\pi_{ss'} = \sum_{a\in\mathcal{A}} \pi(a|s) \sum_r P^{ar}_{ss'} = \sum_{a\in\mathcal{A}} \pi(a|s) P^a_{ss'}$
- Solución: $\mathbf{v}_\pi = (\mathbf{I} - \gamma \mathbf{P}^\pi)^{-1} \mathbf{R}^\pi$ (si invertible)

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Ejemplo: GridWorld

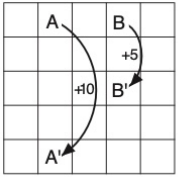

3.3	8.8	4.4	5.3	1.5
1.5	3.0	2.3	1.9	0.5
0.1	0.7	0.7	0.4	-0.4
-1.0	-0.4	-0.4	-0.6	-1.2
-1.9	-1.3	-1.2	-1.4	-2.0

- ¿Cuál es la ecuación de Bellman $v_\pi(A)$?
- ¿Cuál es la ecuación de Bellman $v_\pi(A')$?
- ¿Por qué hay valores negativos y positivos en los bordes?
- ¿Por qué $v(A) < 10$?
- ¿Por qué $v(B) > 5$?

- Cada celda es un estado.
- Se tienen 4 acciones en cada estado: norte, sur, este y oeste. Son equiprobables.
- Estados futuros para cada acción: es determinístico. Dado por la acción.
- Recompensas: -1 si se sale del mundo. 0 en todos los demás.
- Excepciones:
  - Si te sales del mundo vuelves al estado anterior.
  - Si se sale de A se llega directamente a A' con recompensa +10.
  - Si se sale de B se llega directamente a B' con recompensa +5.
- $\gamma = 0{,}9$ para la evaluación $v_\pi(s)$

Desarrollo

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Funciones de Evaluación Óptimas y Políticas Optimas

Definición (Funciones de Valor Óptimas)

- **Función valor de estado óptima:**

$$v_*(s) \doteq \max_\pi v_\pi(s) \quad \forall s \in \mathcal{S}$$

- **Función valor de estado-acción óptima:**

$$q_*(s,a) \doteq \max_\pi q_\pi(s,a) \quad \forall s \in \mathcal{S}, \forall a \in \mathcal{A}$$

Definición (Ordenación (parcial) entre políticas)

$$\pi \geq \pi' \text{ sii } v_\pi(s) \geq v_{\pi'}(s), \forall s$$

Teorema (Existencia de la Política Óptima)

- *Para cualquier Proceso de Decisión de Markov* ***existe una política óptima*** π_* *verificando* $\pi_* \geq \pi \quad \forall \pi$
- *Además* $v_*(s) = v_{\pi_*}(s)$ *y* $q_*(s,a) = q_{\pi_*}(s,a)$

Resultados Previos

$$\pi_*(a \mid s) = \begin{cases} 1 & \text{si } a = \arg\max_{a \in \mathcal{A}} q_*(s,a), \\ 0 & \text{de lo contrario.} \end{cases}$$

$$\begin{aligned} q_{\pi_*}(s,a) &\overset{\cdot}{=} \mathbb{E}_{\pi_*}[G_t | S_t = s, A_t = a] \\ &= \mathbb{E}_{\pi_*}[R_{t+1} + \gamma G_{t+1} | S_t = s, A_t = a] \\ &= \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a] \quad \star \end{aligned}$$

Ecuación de Bellman Óptima para la Función de Valor de Estado

$$\begin{aligned} v_*(s) &= \max_{a \in \mathcal{A}(s)} q_*(s,a) = \max_{a \in \mathcal{A}(s)} q_{\pi_*}(s,a) \\ &\overset{\star}{=} \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a] \end{aligned}$$

Ecuación de Bellman Óptima para la Función de Valor de Estado-Acción

$$\begin{aligned} q_*(s,a) &\overset{\star}{=} \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a] \\ &= \mathbb{E}[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') | S_t = s, A_t = a] \end{aligned}$$

Cálculo de las Funciones de Valor Óptimas

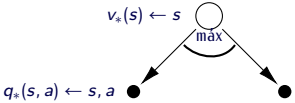

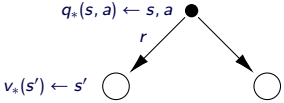

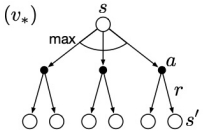

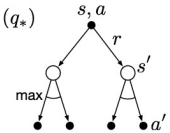

PDM

$$v_*(s) = \max_a q_*(s,a) \qquad q_*(s,a) = R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a v_*(s')$$

$$v_*(s) = \max_a \left(R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a v_*(s') \right) \qquad q_*(s,a) = R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a \max_a q_*(s,a)$$

PDM con Recompensas Estocásticas

$$v_*(s) = \max_a q_*(s,a) \qquad q_*(s,a) = \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} P_{ss'}^{ar} + \gamma \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} P_{ss'}^{ar} v_*(s')$$

$$v_*(s) = \max_a \sum_{s',r} P_{ss'}^{ar} \left(r + \gamma v_*(s') \right] \qquad q_*(s,a) = \sum_{s',r} P_{ss'}^{ar} \left(r + \gamma \max_{a'} q_*(s',a') \right)$$

Resolviendo la Ecuación de Optimalidad de Bellman

- Las ecuaciones de optimalidad de Bellman no son lineales.
- **No existe una solución general** para las ecuaciones.
- **Métodos iterativos:**
  - **Iteración del Valor**: Iteración sobre $v(s)$ hasta convergencia.
  - **Iteracion de la Política**: Alterna entre mejorar la política y evaluar $v(s)$.
  - **Q-learning**: Aproximación para encontrar $q^*(s, a)$.
  - SARSA
  - etc ...

Estos métodos son fundamentales para resolver MDPs en la práctica y **definen las distintas técnicas del Aprendizaje por Refuerzo**.

Profundizamos en ...

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Ejemplo: GridWorld

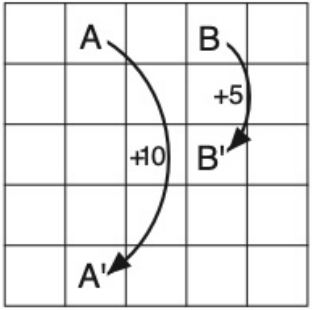

Gridworld

22.0	24.4	22.0	19.4	17.5
19.8	22.0	19.8	17.8	16.0
17.8	19.8	17.8	16.0	14.4
16.0	17.8	16.0	14.4	13.0
14.4	16.0	14.4	13.0	11.7

v_*

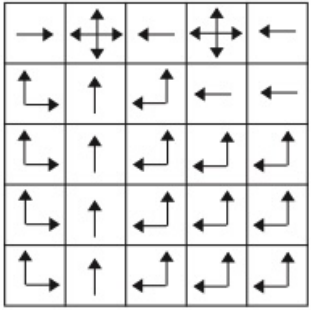

π_*

Desarrollo

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Resumen para la Función Valor de Estado

- **Definición:** $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\middle|\, S_t = s\right], \quad$ para todo $s \in \mathcal{S}$,
- **Ecuación de Bellman:** $v_\pi(s) = \mathbb{E}_\pi\left[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s\right]$
  - Proceso de **Decisión** de Markov
$$v_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a|s) q_\pi(a,s) = \sum_{a\in\mathcal{A}} \pi(a|s) \left(R_s^a + \gamma \sum_{s'\in\mathcal{S}} P_{ss'}^a v_\pi(s')\right)$$
  - Proceso de Decisión de Markov con **Recompensas Estocásticas**
$$v_\pi(s) = \sum_{a\in\mathcal{A}} \pi(a|s) q_\pi(a,s) = \sum_{a\in\mathcal{A}} \pi(a|s) \sum_{s',r} P_{ss'}^{ar} \left(r + \gamma v_\pi(s')\right)$$
- **Ecuación Óptima** de Bellman: $v_*(s) = \max_{a\in\mathcal{A}(s)} q_*(s,a) = \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a]$
  - Proceso de **Decisión** de Markov
$$v_*(s) = \max_a \left(R_s^a + \gamma \sum_{s'\in\mathcal{S}} P_{ss'}^a v_*(s')\right)$$
  - Proceso de Decisión de Markov con **Recompensas Estocásticas**
$$v_*(s) = \max_a \sum_{s',r} P_{ss'}^{ar} \left(r + \gamma v_*(s')\right]$$

Resumen para la Función Valor de Estado-Acción

- **Definición:** $q_\pi(s,a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a] = \mathbb{E}_\pi\left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \,\middle|\, S_t = s, A_t = a\right] \forall s \in \mathcal{S}, \forall a \in \mathcal{A}$
- **Ecuación de Bellman:** $q_\pi(s,a) = \mathbb{E}_\pi\left[R_{t+1} + \gamma q_\pi(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a\right]$
  - Proceso de **Decisión** de Markov:
    $$q_\pi(s,a) = R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a v_\pi(s') = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \sum_{a' \in A} \pi(a' \mid s') q_\pi(s', a')$$
  - Proceso de Decisión de Markov con **Recompensas Estocásticas**
    $$q_\pi(s,a) = \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} P_{ss'}^{ar} + \gamma \sum_{r \in \mathcal{R}} \sum_{s' \in \mathcal{S}} P_{ss'}^{ar} v_\pi(s') = \sum_{s',r} P_{ss'}^{ar} \left(r + \gamma \sum_{a' \in \mathcal{A}} \pi(a' \mid s') q_\pi(s', a') \right)$$
- **Ecuación Óptima** de Bellman: $q_*(s,a) = q_{\pi_*}(s,a) = \mathbb{E}[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') | S_t = s, A_t = a]$
  - Proceso de **Decisión** de Markov:
    $$q_*(s,a) = R_s^a + \gamma \sum_{s' \in \mathcal{S}} P_{ss'}^a \max_a q_*(s,a)$$
  - Proceso de Decisión de Markov con **Recompensas Estocásticas:**
    $$q_*(s,a) = \sum_{s',r} P_{ss'}^{ar} \left(r + \gamma \max_{a'} q_*(s', a') \right)$$

Desarrollo

1. Introducción a los Procesos Estocásticos
   1.1. Variables Aleatorias y sus Distribuciones de Probabilidad
   1.2. Procesos Estocásticos
   1.3. Clasificación de los Procesos Estocásticos
      Procesos de Markov
      Cadenas de Markov
2. Construyendo un Proceso de Decisión de Markov en RL
   2.1. La Interfaz Agente–Entorno
   2.2. Procesos de Markov
   2.3. Procesos de Recompensas de Markov
   2.4. Procesos de Decisión de Markov
   2.5. PDM con Recompensas Estocásticas
   2.6. El ejemplo del GridWorld
3. Políticas Óptimas
   3.1. Optimalidad
   3.2. El ejemplo del GridWorld
4. Resumen
5. Referencias

Referencias

- Mausam and Andrey Kolobov. (2012). *Planning with Markov Decision Processes: An AI Perspective*. Springer International Publishing. https://doi.org/10.1007/978-3-031-01559-5
- Russell, S. J., Russell, S., & Norvig, P. (2022). *Artificial Intelligence: A Modern Approach*. Pearson.
- Silver, D. (2015). Lectures on Reinforcement Learning. https://www.davidsilver.uk/teaching/
- Sutton, R., & Barto, A. (2018). *Reinforcement Learning, second edition: An Introduction*. MIT Press. https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf
- van Hasselt, H. (2018). DeepMind x UCL Reinforcement Learning. http://y2u.be/ISk80iLhdfU