Aprendizaje por Refuerzo

Métodos de Monte Carlo

Luis Daniel Hernández Molinero
Ciencia de la Computación e Inteligencia Artificial
Dept. Ingeniería de la Información y las Comunicaciones

Universidad de Murcia

Máster en Inteligencia Artificial

2025 / 2026

Índice de Contenidos

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Desarrollo

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Introducción

- **Programación Dinámica** requiere el conocimiento completo del proceso.
- Los **métodos de Monte Carlo** se caracterizan por:
  - Es ***sin modelo***: no requieren conocimiento previo de la dinámica del entorno
  - Requieren solo **experiencia**: conocimiento de trayectorias
  - Cualquier Monte Carlo usa **muestras** para realizar estimaciones.
  - Una muestra es finita: MC únicamente para **tareas episódicas**
  - **Solo al completar un episodio**, se estimarán los valores y se actualizan las políticas.
    - No utiliza *bootstrapping*.
- **Métodos de aprendizaje:**
  - **Métodos on-policy:** Evalúan o mejoran la política que se utiliza para tomar decisiones.
  - **Métodos off-policy:** Evalúan o mejoran una política diferente a la que se utiliza para generar los datos.

Desarrollo

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Profundizamos en ...

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
      Evaluación de las funciones $v(s)$
   2.2. Control On-policy
      Evaluación de las funciones $q(s, a)$
      Iteración General de Políticas para MC
      Con inicios exploratorios
      Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Con más detalle ..

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Evaluación de Políticas Monte-Carlo (On-Policy)

- Para **predicción**:
  - Entrada: MDP $\langle S, A, P, R, \gamma \rangle$ y política π.
  - Salida, función de valor v_π.
- En **Programación Dinámica:** : $V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a)[r + \gamma V(s')]$ (utiliza *bootstrapping*)
- Pero **también sabemos** que:
  - **Por definición**, $v_\pi(s) = \mathbb{E}_\pi[G_t|s_t = s]$ con $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$ (**variable aleatoria**).
  - **Ley de los grandes números**, $\mathbb{E}_\pi[G_t|s_t = s] \approx \frac{1}{N} \sum_{i=1}^{N} G_t^{(i)}$. $\quad \mathrm{P}\left(\lim_{n\to\infty} \overline{X}_n = \mu\right) = 1,$
- **Objetivo MC**: Aprender v_π a partir de episodios de experiencia bajo la política π.
  1. Soltar al agente en S_0.
  2. Obtener un episodio: $S_0, A_1, R_1, \dots, S_T, R_T \sim \pi$.
  3. Calcular su retorno: $G_0 = R_1 + \gamma R_2 + \dots + \gamma^{T-1} R_T$
  4. Repetir varias veces los 3 pasos anteriores.
  5. Retornar el promedio de los retornos.

$$\underbrace{S_0, S_1, R_1, \overbrace{S_2, R_2, \underbrace{S_3, R_3 \dots, S_T, R_T}_{G_3}}^{G_1}}_{G_0}$$

Usamos el Proceso de Recompensas de Markov

Evaluación de Políticas por Monte-Carlo
Por Primera visita y por Todas las Visitas

Evaluación de Primera Visita (First-Visit)

$$S_0, S_1, R_1 \ldots, \underbrace{S_i, R_i \ldots, S_i, R_i \ldots S_T, R_T}_{G_i}$$

- Para evaluar el estado s:
  - **Identifica el primer instante** de tiempo t en el que el estado s es visitado en un episodio.
  - Incrementa el contador $N(s) \leftarrow N(s) + 1$.
  - Incrementa el retorno total $S(s) \leftarrow S(s) + G_t$.
- El valor se estima como el retorno promedio: $V(s) = \frac{S(s)}{N(s)}$.
- Según la ley de los grandes números, $V(s) \rightarrow v_\pi(s)$ a medida que $N(s) \rightarrow \infty$.

Evaluación de Todas las Visitas (Every-Visit)

$$S_0, S_1, \ldots, \underbrace{S_i, R_i \ldots, \overbrace{S_i, R_i \ldots S_T, R_T}^{G_i'}}_{G_i}$$

- Para evaluar el estado s:
  - **En cada instante** de tiempo t en el que el estado s es visitado en un episodio:
    1. Incrementa el contador $N(s) \leftarrow N(s) + 1$.
    2. Incrementa el retorno total $S(s) \leftarrow S(s) + G_t$.
- El valor se estima como el retorno promedio: $V(s) = \frac{S(s)}{N(s)}$.
- Nuevamente, $V(s) \rightarrow v_\pi(s)$ a medida que $N(s) \rightarrow \infty$. (Singh & Sutton, 1996)

Actualización incremental: $N(s) \leftarrow N(s) + 1$, $V(s) \leftarrow V(s) + \frac{1}{N(s)}(G_t - V(s))$

Algorithm 1 Predicción MC de primera visita, para estimar $V \approx v_\pi$

First-visit MC prediction, for estimating $V \approx v_\pi$

Input: a policy π to be evaluated

Initialize:

  $V(s) \in \mathbb{R}$, arbitrarily, for all $s \in \mathcal{S}$

  $Returns(s) \leftarrow$ an empty list, for all $s \in \mathcal{S}$

Loop forever (for each episode):

  Generate an episode following π: $S_0, A_0, R_1, S_1, A_1, R_2, \ldots, S_{T-1}, A_{T-1}, R_T$

  $G \leftarrow 0$

  Loop for each step of episode, $t = T-1, T-2, \ldots, 0$:

    $G \leftarrow \gamma G + R_{t+1}$

    Unless S_t appears in $S_0, S_1, \ldots, S_{t-1}$:

      Append G to $Returns(S_t)$

      $V(S_t) \leftarrow \text{average}(Returns(S_t))$

Resumen. Predicción Monte Carlo

- Los métodos Monte Carlo **no usan *bootstraping***.
  - La estimación para un estado no se construye a partir de la estimación de ningún otro estado, como ocurre en la Programación Dinámica (DP).
- El costo computacional de estimar el valor de un solo estado **es independiente** del número total de estados.
- Los métodos Monte Carlo son particularmente **atractivos** cuando se requiere el valor de ***solo uno o un subconjunto de estados***.

Ejemplo de Blackjack

- **Estados** (200 en total):
  - Suma actual (12-21).
  - Carta visible del dealer (as-10).
  - ¿Tengo un as "utilizable"? (sí-no).
- **Acciones**:
  - *Pedir*: recibir otra carta (sin reemplazo).
  - *Plantarse*: detenerse y terminar.
- **Recompensa al plantarse**:
  - $+1$ si la suma de cartas del jugador es mayor que la suma de cartas del croupier.
  - 0 si las sumas son iguales.
  - -1 si la suma del jugador es menor que la suma del croupier.
- **Recompensa al pedir**:
  - -1 si la suma de cartas del jugador > 21 (termina el juego).
  - 0 en caso contrario.
- **Transiciones**: automáticamente pide si la suma de cartas del jugador < 12.
- **Política:** plantarse si la suma de cartas ≥ 20, de lo contrario pedir.

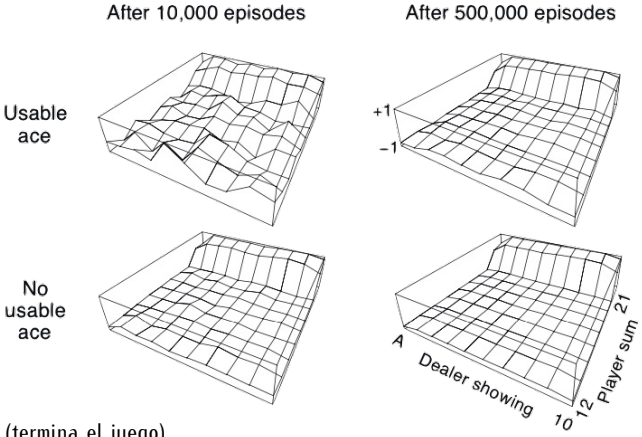

Profundizamos en ...

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Con más detalle ..

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Evaluación de Funciones $q()$ (Control)

- Para **control**:
  - Entrada: MDP $\langle S, A, P, R, \gamma \rangle$.
  - Salida: función de valor óptima $v^*(s)$ y política óptima $\pi^*(s)$
- Para **Programación Dinámica:** $\pi'(s) \leftarrow \arg_a \max q_\pi(s,a) = \arg\max_a \sum_{s',r} p(s',r|s,a)[r + \gamma V(s')]$
- Pero **también sabemos** que:
  - **Por definición**, $q_\pi(s,a) = \mathbb{E}_\pi[G_t|s_t = s, a_t = a]$ con $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$.
  - **Ley de los grandes números:** $\mathbb{E}_\pi[G_t|s_t = s, a_t = a] \approx \frac{1}{N}\sum_{i=1}^{N} G_t^{(i)}$. $\quad \mathrm{P}\left(\lim_{n\to\infty} \overline{X}_n = \mu\right) = 1,$
- **Objetivo MC**: Aprender q_π a partir de episodios de experiencia bajo la política π.
- Ahora en vez de tener en cuenta el estado, hay que tener en cuenta (estado, acción)

$$\underline{S_0, A_0}, \underbrace{R_1, \underline{S_1, A_1} \dots \underline{S_i, A_i}, \overbrace{R_{i+1}, S_{i+1}, \dots, R_T, S_T}^{G_i(S_i,A_i)}}_{G_0(S_0,A_0)}$$

- Se visita un par estado–acción (s,a) en un episodio si el estado s se visita y la acción a se toma en él.
- El método MC de **todas las visitas** estima el valor de un par estado–acción como el promedio de los retornos que siguieron a todas las visitas a este.
- El método MC de **primera visita** promedia los retornos que siguieron a la primera vez en cada episodio en que el estado fue visitado y la acción seleccionada.
- Ambos convergen a los valores esperados verdaderos.

Hay problemas

- Se tiene un **problema de exploración** (como en bandido k-brazos)
  P.e. Si π es una **política determinista**
  - Algunos pares estado-acción pueden no ser visitados nunca.
  - Así es imposible saber si hay alternativas posibles.

- **Soluciones:**
  - **Inicios exploratorios:** $s_0 \sim rnd(\mathcal{S})$ y $a_0 \sim rnd(\mathcal{A}(s_0))$
  - **Políticas estocásticas:** $\pi(s|a) > 0 \quad \forall s \in \mathcal{S}, \forall a \in \mathcal{A}$

Con más detalle ..

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Iteración de Políticas General

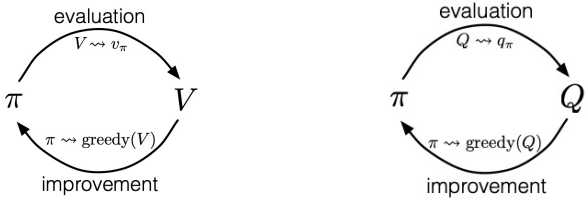

- La idea general de la **Iteración de Políticas**:

$$\pi_0 \xrightarrow{E} v_{\pi_0} \xrightarrow{I} \pi_1 \xrightarrow{E} v_{\pi_1} \xrightarrow{I} \pi_2 \xrightarrow{E} \dots \xrightarrow{I} \pi_* \xrightarrow{E} v_*$$

- **Versión Monte Carlo** de la iteración clásica de políticas.

$$\pi_0 \xrightarrow{\text{E}} q_{\pi_0} \xrightarrow{\text{I}} \pi_1 \xrightarrow{\text{E}} q_{\pi_1} \xrightarrow{\text{I}} \pi_2 \xrightarrow{\text{E}} \cdots \xrightarrow{\text{I}} \pi_* \xrightarrow{\text{E}} q_*$$

  - **Evaluación:** Simulación por muestras de cada $q_{\pi_k}(s, a)$
  - **Mejora**: $\pi_{k+1}(s) = \arg\max_a q_{\pi_k}(s, a)$
  - **Hipótesis:** un número infinito de episodios + los episodios *se generan con inicios exploratorios.*
    - los métodos de Monte Carlo calcularán cada q_{π_k} exactamente, para π_k arbitrarias.
    - Se sigue cumpliento el teorema de mejora de políticas
      Como $q_{\pi_k}(s, \pi_{k+1}(s)) \geq v_{\pi_k}(s)$, entonces $v_{\pi_{k+1}}(s) \geq v_{\pi_k}(s)$ (π_{k+1} es tan buena como π_k)
  - **En la práctica** renunciamos al número infinito de episodios (Renunciamos a una evaluación exacta).

$$\pi_0 \xrightarrow{\text{E}} Q_{\pi_0} \xrightarrow{\text{I}} \pi_1 \xrightarrow{\text{E}} Q_{\pi_1} \xrightarrow{\text{I}} \pi_2 \xrightarrow{\text{E}} \cdots \xrightarrow{\text{I}} \pi_* \xrightarrow{\text{E}} q_*$$

Con más detalle ..

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Algorithm 2 Monte Carlo ES (Exploring Starts), para estimar $\pi \approx \pi_*$

Monte Carlo ES (Exploring Starts), for estimating $\pi \approx \pi_*$

Initialize:
- $\pi(s) \in \mathcal{A}(s)$ (arbitrarily), for all $s \in \mathcal{S}$
- $Q(s,a) \in \mathbb{R}$ (arbitrarily), for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$
- $Returns(s,a) \leftarrow$ empty list, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

Loop forever (for each episode):
- Choose $S_0 \in \mathcal{S}$, $A_0 \in \mathcal{A}(S_0)$ randomly such that all pairs have probability > 0
- Generate an episode from S_0, A_0, following π: $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$
- $G \leftarrow 0$
- Loop for each step of episode, $t = T-1, T-2, \ldots, 0$:
  - $G \leftarrow \gamma G + R_{t+1}$
  - Unless the pair S_t, A_t appears in $S_0, A_0, S_1, A_1 \ldots, S_{t-1}, A_{t-1}$:
    - Append G to $Returns(S_t, A_t)$
    - $Q(S_t, A_t) \leftarrow \text{average}(Returns(S_t, A_t))$
    - $\pi(S_t) \leftarrow \arg\max_a Q(S_t, a)$

- Los returns se acumulan **independientemente** de la política que los observó.
- No converge a una política subóptima

Resolver el Blackjack por MC

- Queremos resolver Blackjack por MC-ES
- Para garantizar la exploración completa:
  - Se seleccionan al azar las cartas del crupier.
  - Se elige la suma inicial del jugador.
  - Se determina si el jugador tiene o no un as utilizable.
  - Todas las combinaciones posibles se generan con igual probabilidad.
- Política inicial: Se planta solo con sumas de 20 o 21, de lo contrario pedir.
- Los valores iniciales de la función de valor de acción ($Q(s, a)$) se establecen en cero para todos los pares estado-acción.
- El jugador aplica una política diferente dependiendo de si tiene o no un as utilizable.

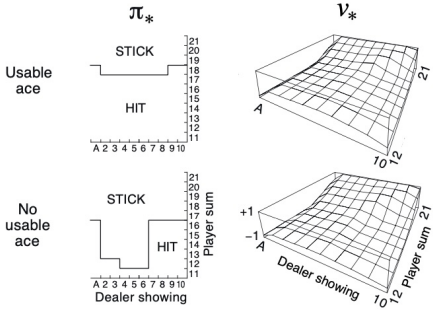

Con más detalle ..

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Iteración de Valor versión Monte Carlo con Soft-Policy
Sutton y Barto, 2018

- **Recuerda**. Las soluciones para garantizar que sean seleccionados los pares (estado, acción):
  - **Inicios exploratorios:** $s_0 \sim rnd(\mathcal{S})$ y $a_0 \sim rnd(\mathcal{A}(s_0))$
  - **Políticas estocásticas:** $\pi(s|a) > 0 \quad \forall s \in \mathcal{S}, \forall a \in \mathcal{A}$
- **Política suave (soft-policy):** $\pi(a|s) > 0$ para todos los $s \in \mathcal{S}$ y $a \in \mathcal{A}$.
- **Política ϵ-soft:** $\pi(a|s) \geq \dfrac{\epsilon}{|\mathcal{A}(s)|}$ para todos los $s \in \mathcal{S}$ y $a \in \mathcal{A}$, donde $\epsilon > 0$.

  La acción codiciosa (greedy) se selecciona con probabilidad: $1 - \epsilon + \dfrac{\epsilon}{|\mathcal{A}(s)|}$ mientras que una acción no codiciosa específica se selecciona con probabilidad: $\dfrac{\epsilon}{|\mathcal{A}(s)|}$.
  - **Las políticas ϵ-greedy son políticas ϵ-*soft***

$$a^* \leftarrow \begin{cases} \arg\max_a Q_\pi(s,a) & \text{con probabilidad } 1 - \epsilon + \frac{\epsilon}{|\mathcal{A}(s)|} \\ \text{acción no greedy} & \text{con probabilidad } \frac{\epsilon}{|\mathcal{A}(s)|} \end{cases} \qquad \text{(rompiendo aleatoriamente)}$$

- **Generalized Policy Iteration (GPI):** No requiere que la política se lleve completamente a una política-greedy, solo que se mueva en dirección hacia una política-greedy, de forma análoga a que tampoco evaluamos completamente las funciones de valor.

La Iteración de Políticas Funciona para Políticas Greedy sobre Políticas ϵ-soft.

- Cualquier política π' que sea ϵ-*greedy* con respecto a q_π *es una mejora* sobre cualquier política ϵ-*soft*, π,
  - Se cumple que: $q_\pi(s, \pi'(s)) \geq v_\pi(s)$

$$
\begin{aligned}
q_\pi(s, \pi'(s)) &= \sum_a \pi'(a|s) q_\pi(s, a) \\
&= \frac{\varepsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) + (1 - \varepsilon) \max_a q_\pi(s, a) \\
&\geq \frac{\varepsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) + (1 - \varepsilon) \sum_a \left(\pi(a|s) - \frac{\varepsilon / |\mathcal{A}(s)|}{1 - \varepsilon} \right) q_\pi(s, a) \\
&= \frac{\varepsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) - \frac{\varepsilon}{|\mathcal{A}(s)|} \sum_a q_\pi(s, a) + \sum_a \pi(a|s) q_\pi(s, a) \\
&= v_\pi(s).
\end{aligned}
$$

  - **Por el teorema de mejora de políticas**, $\pi' \succeq \pi$ (es decir, $v_{\pi'}(s) \geq v_\pi(s)$ para todo $s \in S$).
- $v_{\pi'}(s) = v_\pi(s)$ para todo $s \in S$ solo cuando **tanto π' como π son óptimas entre las políticas ϵ-soft**; es decir, cuando son mejores o iguales que todas las demás políticas ϵ-soft (Sutton & Barto, 2018).

Iteración de Valor versión Monte Carlo con Políticas ϵ-soft

Algorithm 3 *On-policy* Control Monte Carlo de primera visita (para políticas ϵ-*soft*)

On-policy first-visit MC control (for ε-soft policies), estimates $\pi \approx \pi_*$

Algorithm parameter: small $\varepsilon > 0$
Initialize:
  $\pi \leftarrow$ an arbitrary ε-soft policy
  $Q(s,a) \in \mathbb{R}$ (arbitrarily), for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$
  $Returns(s,a) \leftarrow$ empty list, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

Repeat forever (for each episode):
  Generate an episode following π: $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$
  $G \leftarrow 0$
  Loop for each step of episode, $t = T-1, T-2, \ldots, 0$:
    $G \leftarrow \gamma G + R_{t+1}$
    Unless the pair S_t, A_t appears in $S_0, A_0, S_1, A_1 \ldots, S_{t-1}, A_{t-1}$:
      Append G to $Returns(S_t, A_t)$
      $Q(S_t, A_t) \leftarrow \text{average}(Returns(S_t, A_t))$
      $A^* \leftarrow \arg\max_a Q(S_t, a)$ (with ties broken arbitrarily)
      For all $a \in \mathcal{A}(S_t)$:

$$\pi(a|S_t) \leftarrow \begin{cases} 1 - \varepsilon + \varepsilon/|\mathcal{A}(S_t)| & \text{if } a = A^* \\ \varepsilon/|\mathcal{A}(S_t)| & \text{if } a \neq A^* \end{cases}$$

Desarrollo

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Métodos off-Policy

- **Métodos off-policy:** Evalúan o mejoran una política diferente a la que se utiliza para generar los datos.
- **En consecuencia**, dado que los datos provienen de una política diferente, los métodos off-policy generalmente:
  - Sufren de mayor varianza.
  - Son más lentos para converger.
- **Son más** poderosos y generales.
  - Los métodos on-policy son un caso especial.
- Pueden aplicarse para **aprender a partir de datos generados** por un controlador convencional no basado en aprendizaje, o por un experto humano.

Profundizamos en ...

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Evaluación de Políticas Monte-Carlo (Off-Policy)
Muestreo por Importancia

- Consideremos el problema de predicción, en el cual tanto la **política objetivo** (π, *target policy*) como la **política de comportamiento** (b, *behavior policy*) están fijas.
  - Queremos estimar v_π o q_π, pero solo tenemos episodios generados siguiendo la política b, donde $b \neq \pi$.
- $b()$ **debe cumplir ciertas condiciones.**
  - **Suposición de cobertura:** Toda acción tomada bajo π también debe tomarse, al menos ocasionalmente, bajo b.
  $$\pi(a|s) > 0 \implies b(a|s) > 0.$$
  - $b()$ debe ser **estocástica**.
  A pesar de que $\pi(a|s) = 0$, debe cumplirse $b(a|s) > 0$.
- Casi todos los métodos *off-policy* utilizan el **muestreo de importancia** (esquema general):
  - Queremos calcular un valor esperado bajo una distribución objetivo π: $\mathbb{E}_\pi[f(x)] = \int f(x)\pi(x)dx$,
  - Podemos expresarlo como $\mathbb{E}_\pi[f(x)] = \int f(x)\frac{\pi(x)}{b(x)}b(x)dx = \int f(x)w(x)b(x)dx$, con $w(x) = \frac{\pi(x)}{b(x)}$.
    - **Coeficiente de muestreo de importancia:** $w(x)$
    - $\mathbb{E}_\pi\big[f(x)\big] = \mathbb{E}_b\Big[f(x) \cdot w(x)\Big]$
  - Entonces $\boxed{\mathbb{E}_\pi[f(x)] \approx \frac{1}{N}\sum_{i=1}^{N} f(x_i)w(x_i) \text{ tomando muestras } x_i \sim b(x)}$

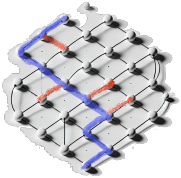

$G_\pi(s) = w(s)G_b(s)$

Adaptación del Muestreo por Importancia para Predicción

- **Nuestro objetivo** es estimar $v_\pi(s)$ muestreando con una política $b(s)$ y usando muestreo por importancia.
- Consideramos un **episodio aleatorio:** $H_{S_t} = A_t, S_{t+1}, A_{t+1}, \ldots, S_T$
- **Las probabilidades** bajo las políticas π y b **son:**
  - $$\begin{aligned} P(H_{S_t} \sim \pi) &= P_\pi\{A_t, S_{t+1}, A_{t+1}, \ldots, S_T \mid S_t, A_{t:T-1}\} \\ &= \pi(A_t \mid S_t)p(S_{t+1} \mid S_t, A_t)\pi(A_{t+1} \mid S_{t+1}) \cdots p(S_T \mid S_{T-1}, A_{T-1}) \\ &= \prod_{k=t}^{T-1} \pi(A_k \mid S_k)p(S_{k+1} \mid S_k, A_k), \end{aligned}$$
  - $P(H_{S_t} \sim b) = \prod_{k=t}^{T-1} b(A_k \mid S_k)p(S_{k+1} \mid S_k, A_k)$
- El **peso de importancia** (*importance-sampling ratio*) para un episodio es:
$$w(H_{S_t}) = \rho_{t:T-1} = \prod_{k=t}^{T-1} \frac{\pi(A_k|S_k)}{b(A_k|b_k)}.$$
- **Reescribimos el valor esperado:** $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_b[\rho_{t:T-1} G_t \mid S_t = s]$

Predicción Off-Policy con Muestreo por Importancia

- Los pasos de tiempo serán **consecutivos**. No se "resetea" para cada episodio.
- $\mathcal{T}(s)$ es el **conjunto de pasos de tiempo** en los que el estado s es visitado
  - **Primera Visita**: los pasos de tiempo en los que se realizaron las *primeras visitas* a s dentro de sus episodios
  - **Todas las Visitas**: *todos* los pasos de tiempo donde s fue visitado.
- $T(t)$: el **primer tiempo** de terminación posterior al tiempo t.
- G_t: el **retorno** después de t hasta $T(t)$.
- Luego, $\{G_t\}_{t\in\mathcal{T}(s)}$ son los **retornos relacionados** con el estado s
- $\{\rho_{t:T(t)-1}\}_{t\in\mathcal{T}(s)}$ son los correspondientes **coeficientes de muestreo por importancia**.
- **Muesteo por importancia ordinario:** Para estimar $v_\pi(s)$, escala los retornos por los coeficientes de muestreo por importancia y promedia los resultados:

$$V(s) = \frac{\sum_{t\in\mathcal{T}(s)} \rho_{t:T(t)-1} G_t}{|\mathcal{T}(s)|}.$$

- **Muestreo de importancia ponderado:**

$$V(s) \doteq \frac{\sum_{t\in\mathcal{T}(s)} \rho_{t:T(t)-1} G_t}{\sum_{t\in\mathcal{T}(s)} \rho_{t:T(t)-1}}, \text{ o cero si el denominador es cero.}$$

Comparación entre Muestreo de Importancia Ordinario y Ponderado

Características	Muestreo de Importancia Ordinario	Muestreo de Importancia Ponderado
Fórmula de Estimación	$V(s) \doteq \frac{\sum_{t \in \mathcal{T}(s)} \rho_{t:T(t)-1} G_t}{\lvert \mathcal{T}(s) \rvert}$. Promedio simple de retornos escalados por las razones de importancia.	$V(s) \doteq \frac{\sum_{t \in \mathcal{T}(s)} \rho_{t:T(t)-1} G_t}{\sum_{t \in \mathcal{T}(s)} \rho_{t:T(t)-1}}$, Promedio ponderado de retornos escalados por las razones de importancia.
	Primera Visita	
Sesgo	▶ **No sesgado**: $\mathbb{E}[V(s)] = v_\pi(s)$.	▶ **Sesgado**: $\mathbb{E}[V(s)] \approx v_b(s)$. ▶ El sesgo converge a cero asintóticamente.
Varianza	▶ **Alta y potencialmente ilimitada**: Depende de la variabilidad de las razones ρ. ▶ Puede ser extrema si ρ es grande (e.g., transparencia posterior).	▶ **Menor varianza**: Normalización reduce el impacto de ρ grandes. ▶ La varianza converge a cero si los retornos están acotados, incluso si $\mathrm{Var}(\rho)$ es infinita.
Convergencia	▶ La expectativa está alineada con $v^\pi(s)$, pero con alta varianza puede requerir más muestras.	▶ Aunque sesgado, la menor varianza suele conducir a estimaciones más estables y eficientes en la práctica.
Preferencia Práctica	▶ Menos preferido debido a la alta varianza. ▶ Más fácil de extender a métodos aproximados usando aproximación funcional.	▶ Generalmente preferido en la práctica por su varianza significativamente menor. ▶ Usado comúnmente en algoritmos de Monte Carlo de todas las visitas.
Todas las Visitas	▶ Ambas variantes (ordinario y ponderado) son sesgadas en métodos de visita múltiple. ▶ El sesgo disminuye asintóticamente con el aumento del número de muestras.	Son preferidos "Todas las visitas"porque ▶ Eliminan la necesidad de llevar un registro de qué estados han sido visitados ▶ Son mucho más fáciles de extender a aproximaciones.

Estimación off-policy del valor de un estado en Blackjack
Curvas de aprendizaje

- Se aplicaron tanto métodos de **muestreo de importancia ordinario** como **muestreo de importancia ponderado** para estimar el valor de un único estado en Blackjack.
- Estado evaluado: $v_\pi(s) \approx 0{,}27726$ para 100 millones de episodios on-policy
  - $s =$*(El crupier muestra un dos, La suma de las cartas del jugador es 13, El jugador tiene un as utilizable)*
- La **política de comportamiento** es pedir o plantarse con igual probabilidad.
- La **política objetivo** consiste en plantarse solo con una suma de 20 o 21.

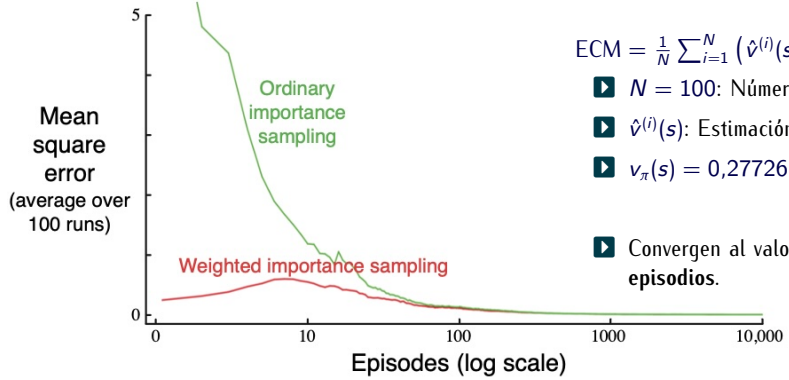

$\text{ECM} = \frac{1}{N}\sum_{i=1}^{N}\left(\hat{v}^{(i)}(s) - v_\pi(s)\right)^2$ Donde:

- $N = 100$: Número de ejecuciones independientes.
- $\hat{v}^{(i)}(s)$: Estimación en la i-ésima ejecución.
- $v_\pi(s) = 0{,}27726$: Valor verdadero del estado.

- Convergen al valor verdadero después de **10,000 episodios**.

Varianza Infinita en Muestreo de Importancia Ordinario

- Las estimaciones del muestreo de importancia ordinario típicamente tienen **varianza infinita** si los retornos escalados tienen varianza infinita.
  - Esto es común en aprendizaje *off-policy* si las trayectorias contienen bucles.
- Ejemplo:

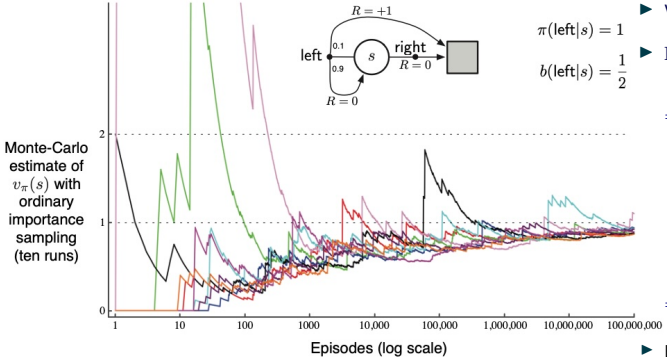

$\pi(\text{left}|s) = 1$

$b(\text{left}|s) = \frac{1}{2}$

- $v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_b[\rho_{t:T-1} G_t \mid S_t = s]$
- $\text{Var}[X] = \mathbb{E}\left[(X - \bar{X})^2\right] = \mathbb{E}[X^2] - \bar{X}^2$.
- $\mathbb{E}_b\left[\left(\prod_{t=0}^{T-1} \frac{\pi(A_t|S_t)}{b(A_t|S_t)} G_0\right)^2\right] =$

$$= \frac{1}{2} \cdot 0{,}1 \left(\frac{1}{0{,}5}\right)^2 \quad \text{(el episodio de longitud 1)}$$

$$+ \frac{1}{2} \cdot 0{,}9 \cdot \frac{1}{2} \cdot 0{,}1 \left(\frac{1}{0{,}5 \cdot 0{,}5}\right)^2 \quad \text{(el episodio de longitud 2)}$$

$$+ \frac{1}{2} \cdot 0{,}9 \cdot \frac{1}{2} \cdot 0{,}9 \cdot \frac{1}{2} \cdot 0{,}1 \left(\frac{1}{0{,}5 \cdot 0{,}5 \cdot 0{,}5}\right)^2 \quad \text{(el episodio de longitud 3)}$$

$$+ \cdots$$

$$= 0{,}1 \sum_{k=1}^{\infty} \left(\frac{1}{2}\right)^k 0{,}9^{k-1} 2^{2k} = 0{,}1 \sum_{k=0}^{\infty} 0{,}9^k \cdot 2^k \cdot 2 = 0{,}2 \sum_{k=0}^{\infty} 1{,}8^k = \infty.$$

- Existe **desalineación de políticas**: $b() << \pi()$.

- El algoritmo de **muestreo de importancia ponderado** **resuelve este problema**:
  - Estimación de $V(s)$ es exactamente 1 después del primer episodio consistente.
  - Los retornos inconsistentes (terminados con derecha) tienen una razón de muestreo de importancia de $\rho = 0$ y no contribuyen al cálculo.

Versión Incremental

- Estamos interesados en $V(s) = \mathbb{E}_\pi[G_t|S_t = s]$ y tenemos una secuencia de retornos $G_1, G_2, \ldots, G_{n-1}$, todos comenzando en el mismo estado s.
- Generamos un episodio desde s, calculamos G_n y actualizamos V_{n+1} para todo $n \geq 1$.
- **On-policy:** $V(s) = \mathbb{E}_\pi[G_t|S_t = s] \approx V_n = \dfrac{\sum_{k=1}^{n-1} G_k}{n-1}$.
  1. $V_{n+1} = V_n + \frac{1}{n}(G_n - V_n)$.
- **Off-policy ordinario:** $V(s) = \mathbb{E}_b[\rho_{t:T-1} G_t \mid S_t = s] \approx V_n = \dfrac{\sum_{k=1}^{n-1} \rho_{t_k:T(t_k)-1} G_k}{n-1} = \dfrac{\sum_{k=1}^{n-1} W_k G_k}{n-1}$.
  1. $W_n = \rho_{t_n:T(t_n)-1}$
  2. $V_{n+1} = V_n + \frac{1}{n}(W_n G_n - V_n)$
- **Off-policy ponderado:** $V(s) = \mathbb{E}_b[\rho_{t:T-1} G_t \mid S_t = s] \approx V_n = \dfrac{\sum_{k=1}^{n-1} \rho_{t_k:T(t_k)-1} G_k}{\sum_{k=1}^{n-1} \rho_{t_k:T(t_k)-1}} = \dfrac{\sum_{k=1}^{n-1} W_k G_k}{\sum_{k=1}^{n-1} W_k}$.
  1. $W_n = \rho_{t_n:T(t_n)-1}$
  2. $C_n = C_{n-1} + W_n$
  3. $V_{n+1} = V_n + \dfrac{W_n}{C_n}(G_n - V_n)$

Predicción *Off-policy* MC todas las visitas para estimar $V \approx v_\pi$

Algorithm 4 Predicción fuera de política MC para estimar $V \approx v_\pi$

Entrada: una política objetivo arbitraria π
  INICIALIZAR, para todos los $s \in S$:
    $V(s) \in \mathbb{R}$ (inicializado arbitrariamente)
    $C(s) \leftarrow 0$ (pesos acumulativos de muestreo de importancia)
  while True, (para cada episodio) **do**
    SELECCIONAR una política de comportamiento b con cobertura de π
    GENERAR un episodio siguiendo b: $S_0, A_0, R_1, S_1, \ldots, S_{T-1}, A_{T-1}, R_T$
    $G \leftarrow 0$ # Inicializar el retorno acumulado
    $W \leftarrow 1$ # Inicializar el peso acumulado
    for cada paso del episodio en orden inverso $t = T-1, T-2, \ldots, 0$, mientras $W \neq 0$: **do**
      $G \leftarrow \gamma G + R_{t+1}$ # Actualizar el retorno acumulado
      $C(S_t) \leftarrow C(S_t) + W$ # Actualizar el peso acumulado para S_t
      $V(S_t) \leftarrow V(S_t) + \frac{W}{C(S_t)}[G - V(S_t)]$ # Actualización incremental del valor del estado S_t
      $W \leftarrow W \cdot \dfrac{\pi(A_t|S_t)}{b(A_t|S_t)}$ # Actualizar el peso de importancia
    end for
  end while

1. $W_n = \rho_{t_n:T(t_n)-1}$
2. $C_n = C_{n-1} + W_n$
3. $V_{n+1} = V_n + \dfrac{W_n}{C_n}(G_n - V_n)$

Algorithm 5 Predicción MC off-Policy, para estimar $Q \approx q_\pi$

Off-policy MC prediction (policy evaluation) for estimating $Q \approx q_\pi$

Input: an arbitrary target policy π
Initialize, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$:
    $Q(s,a) \in \mathbb{R}$ (arbitrarily)
    $C(s,a) \leftarrow 0$

Loop forever (for each episode):
    $b \leftarrow$ any policy with coverage of π
    Generate an episode following b: $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$
    $G \leftarrow 0$
    $W \leftarrow 1$
    Loop for each step of episode, $t = T-1, T-2, \ldots, 0$, while $W \neq 0$:
        $G \leftarrow \gamma G + R_{t+1}$
        $C(S_t, A_t) \leftarrow C(S_t, A_t) + W$
        $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \frac{W}{C(S_t, A_t)} [G - Q(S_t, A_t)]$
        $W \leftarrow W \frac{\pi(A_t|S_t)}{b(A_t|S_t)}$

Profundizamos en ...

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Control Monte Carlo Off-Policy

- Los métodos de control Monte Carlo **off-policy** **se caracterizan** porque
  - Siguen una **política de comportamiento** para aprender (experiencia, episodios), $b(a|s)$.
  - Mejoran una **política objetivo**, $\pi(a|s)$.
- **Condiciones** sobre la política de comportamiento $b()$:
  - Política de **comportamiento suave** (*soft*). $b(a|s) > 0 \ \forall a$
    - **Cobertura**. Si $\pi(a|s) > 0$, $b(a|s) > 0$.
    - **Estocástica**. Si $\pi(a|s) = 0$, $b(a|s) > 0$.
  - P.e. que sea ϵ-**soft**: $b(a|s) \geq \dfrac{\epsilon}{|\mathcal{A}(s)|}$ para todos los $s \in \mathcal{S}$ y $a \in \mathcal{A}$, donde $\epsilon > 0$.
- Nos basamos en el **Método de Iteración de Políticas General**:
  - **Evaluación**
    - $b()$ será una política soft
    - Aplicar Predicción MC off-policy para estimar $Q \approx q_\pi$
  - **Mejora**
    - Aplicar una política greedy sobre Q

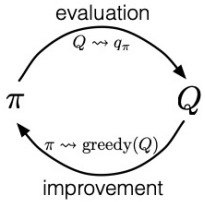

Control Monte Carlo sin Inicios Exploratorios

Algorithm 6 *Off-policy* MC control para estimar $\pi \approx \pi_*$

Off-policy MC control, for estimating $\pi \approx \pi_*$

Initialize, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$:
- $Q(s,a) \in \mathbb{R}$ (arbitrarily)
- $C(s,a) \leftarrow 0$
- $\pi(s) \leftarrow \arg\max_a Q(s,a)$ (with ties broken consistently)

Loop forever (for each episode):
- $b \leftarrow$ any soft policy
- Generate an episode using b: $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$
- $G \leftarrow 0$
- $W \leftarrow 1$
- Loop for each step of episode, $t = T-1, T-2, \ldots, 0$:
  - $G \leftarrow \gamma G + R_{t+1}$
  - $C(S_t, A_t) \leftarrow C(S_t, A_t) + W$
  - $Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \frac{W}{C(S_t, A_t)} [G - Q(S_t, A_t)]$
  - $\pi(S_t) \leftarrow \arg\max_a Q(S_t, a)$ (with ties broken consistently)
  - If $A_t \neq \pi(S_t)$ then exit inner Loop (proceed to next episode)
  - $W \leftarrow W \frac{1}{b(A_t|S_t)}$

Desarrollo

1. Introducción

2. Métodos On-Policy
   2.1. Predicción On-policy MC
   Evaluación de las funciones $v(s)$
   2.2. Control On-policy
   Evaluación de las funciones $q(s, a)$
   Iteración General de Políticas para MC
   Con inicios exploratorios
   Con políticas ϵ-soft

3. Métodos Off-Policy
   3.1. Predicción Off-policy MC
   3.2. Control Off-policy

4. Referencias

Referencias

- Silver, D. (2015). Lectures on Reinforcement Learning. https://www.davidsilver.uk/teaching/
- Singh, S. P., & Sutton, R. S. (1996).Reinforcement learning with replacing eligibility traces. *Machine Learning, 22*(1-3), 123-158. https://doi.org/10.1007/BF00114726
- Sutton, R., & Barto, A. (2018). *Reinforcement Learning, second edition: An Introduction*. MIT Press. https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf