Aprendizaje por Refuerzo

Métodos Basados en el Gradiente de la Política

Luis Daniel Hernández Molinero
Ciencia de la Computación e Inteligencia Artificial
Dept. Ingeniería de la Información y las Comunicaciones

Universidad de Murcia

Máster en Inteligencia Artificial

2025 / 2026

Índice de Contenidos

1. Introducción

2. Fundamentos de los Métodos del Gradiente de la Política

3. REINFORCE

4. Métodos Actor–Crítico

5. Referencias

Desarrollo

1. Introducción

2. Fundamentos de los Métodos del Gradiente de la Política

3. REINFORCE

4. Métodos Actor–Crítico

5. Referencias

Introducción

- Aquí consideramos métodos que aprenden una **política parametrizada** que puede seleccionar acciones **sin consultar una función de valor**.
  - Una función de valor aún puede usarse para aprender el parámetro de la política, pero no es necesaria para la selección de acciones.
  - Usamos la notación $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ para el vector de **parámetros de la política**.
  - $\pi(a|s, \boldsymbol{\theta}) = \Pr\{A_t = a \mid S_t = s, \boldsymbol{\theta}_t = \boldsymbol{\theta}\}$ es la probabilidad de que se tome la acción a en el tiempo t, dado que el entorno está en el estado s en el tiempo t **con el parámetro** $\boldsymbol{\theta}$.
  - Si un método también utiliza una función de valor aprendida, entonces el **vector de pesos de la función de valor** se denota como $\mathbf{w} \in \mathbb{R}^d$, como en $\hat{v}(s, \mathbf{w})$.
    - Los métodos que aprenden aproximaciones tanto para la política como para las funciones de valor a menudo se denominan **métodos actor-crítico**, donde el **actor** se refiere a la política aprendida y el **crítico** se refiere a la función de valor aprendida, usualmente una función de valor-estado.
- Aprenderemos el parámetro de la política **basados en alguna medida escalar de rendimiento** $J(\boldsymbol{\theta})$ tal que
$$\pi^{opt} = \arg\max_{\boldsymbol{\theta}} J(\boldsymbol{\theta})$$
- R. S. Sutton et al., 1999 introducen los **métodos de gradiente de política** como las que buscan maximizar el rendimiento mediante actualizaciones que aproximan el ascenso por gradiente en J:
$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \alpha \widehat{\nabla J(\boldsymbol{\theta}_t)}$$
donde $\widehat{\nabla J(\boldsymbol{\theta}_t)} \in \mathbb{R}^{d'}$ es una **estimación estocástica** cuya **expectativa aproxima el gradiente** de la medida de rendimiento.

Ejemplo: Un Pasillo muy corto con Acciones Invertidas

$$J(\boldsymbol{\theta}) = v_{\pi_{\boldsymbol{\theta}}}(\mathsf{S})$$

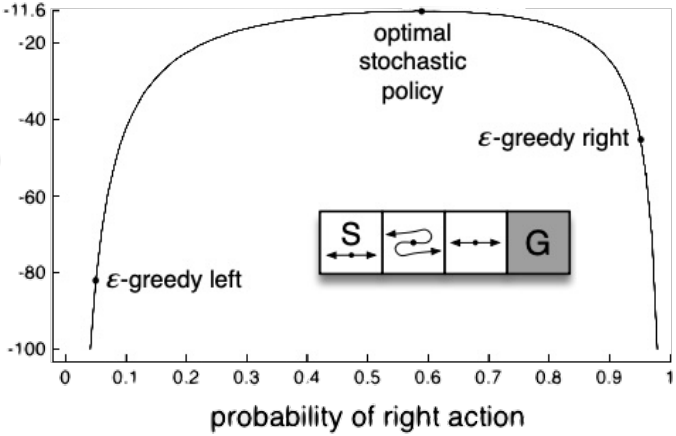

Desarrollo

1. Introducción

2. Fundamentos de los Métodos del Gradiente de la Política

3. REINFORCE

4. Métodos Actor–Crítico

5. Referencias

Cómo Obtener la Política

- La política puede parametrizarse siempre que:
  - $\nabla\pi(a|s,\theta)$ **debe existir y ser finito** para todos $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$, y $\theta \in \mathbb{R}^{d'}$
  - $\pi(a|s,\theta) \in (0,1)$ para que **nunca se vuelva determinística**.
- Se define un **sistema de preferencias parametrizada** con $h(s,a,\theta)$ sobre cada par estado-acción (**finito**).
  - Si es *pequeño*, lo establece el usuario para cada par (s,a).
  - Alternativamente usando **funciones de aproximación parametrizada**:
    - **Representación lineal:** $h(s,a,\theta) = \theta^\top \mathbf{x}(s,a) \in \mathbb{R}^{d'}$, para características $\mathbf{x}$
    - **Redes neuronales:** $h(s,a,\theta) = NN(s,a,\theta)$
    - **Funciones separables:** $h(s,a,\theta) = f_1(s,\theta) + f_2(a,\theta)$
- Se define la política como una **soft-max en preferencias de acción**: $\pi(a|s,\theta) \doteq \dfrac{e^{h(s,a,\theta)}}{\sum_b e^{h(s,b,\theta)}}$.
  - El soft-max en preferencias de acción permite que la política aproximada converja a una **política determinista**, algo que no ocurre con la selección ε-codiciosa.
  - El soft-max facilita la selección de acciones con **probabilidades arbitrarias**, crucial para problemas donde la política óptima es inherentemente estocástica, como en el póker.
    - Los métodos basados en valores de acción no encuentran políticas estocásticas óptimas de forma natural, pero los métodos de aproximación de políticas sí lo logran.

Función de Desempeño
Y su optimización

- La **función de desempeño** $J(\theta)$ resume el desempeño global de la política (en términos de recompensas):

  1. **Recompensa acumulada esperada desde un estado inicial:** $J(\theta) \doteq v_{\pi_\theta}(s_0) = \mathbb{E}_{\tau\sim\pi_\theta}\left[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t)\right]$,

     – τ es una trayectoria generada por la política π_θ, – γ es el factor de descuento,
     – $r(s_t, a_t)$ es la recompensa inmediata en el tiempo t.

  2. **Recompensa promedio por paso** (para entornos ergódicos): $J(\theta) \doteq r(\pi_\theta) = \lim_{T\to\infty} \frac{1}{T}\mathbb{E}_{\tau\sim\pi_\theta}\left[\sum_{t=0}^{T} r(s_t, a_t)\right]$.

- **Teorema del gradiente de política**:

$$\boxed{\nabla J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s, a) \nabla \pi(a|s, \theta)}$$

  - Es un valor esperado respecto de $\mu(s)$. Podemos hacer muestreo.

- **Método *all-actions***

  - De acuerdo al **teorema del gradiente**, $\nabla J(\theta) \propto H(\theta) = \mathbb{E}_\pi\left[\sum_a q_\pi(S_t, a) \nabla \pi(a|S_t, \theta)\right]$.
  - De acuerdo a la **actualización por ascenso del gradiente**: $\theta_{t+1} \doteq \theta_t + \alpha \sum_a \hat{q}(S_t, a, \mathbf{w}) \nabla \pi(a|S_t, \theta)$,

    - Pues $\theta_{t+1} = \theta_t + \alpha \widehat{\nabla J(\theta_t)}$ donde $\widehat{\nabla J(\theta_t)} \in \mathbb{R}^{d'}$ es una estimación.

Desarrollo

1. Introducción

2. Fundamentos de los Métodos del Gradiente de la Política

3. REINFORCE

4. Métodos Actor–Crítico

5. Referencias

Algoritmos REINFORCE

- Partimos de dos resultados:
  - **Teorema del gradiente de política** (R. S. Sutton et al., 2001).

$$\nabla J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s,a) \nabla \pi(a|s,\theta) = H(\theta)$$

  - El método de gradiente de la política que **actualiza por ascenso del gradiente**:

$$\theta_{t+1} = \theta_t + \alpha \widehat{\nabla J(\theta_t)} \qquad \text{donde } \widehat{\nabla J(\theta_t)} \in \mathbb{R}^{d'} \text{ es una estiamación.}$$

- **REINFORCE**

$$\begin{aligned} H(\theta) &= \mathbb{E}_\pi \left[\sum_a \frac{\pi(a|S_t,\theta) q_\pi(S_t,a) \nabla \pi(a|S_t,\theta)}{\pi(a|S_t,\theta)} \right] = \mathbb{E}_\pi \left[q_\pi(S_t,A_t) \frac{\nabla \pi(A_t|S_t,\theta)}{\pi(A_t|S_t,\theta)} \right] \\ &= \mathbb{E}_\pi \left[\mathbb{E}_\pi[G_t|S_t,A_t] \frac{\nabla \pi(A_t|S_t,\theta)}{\pi(A_t|S_t,\theta)} \right] = \mathbb{E}_\pi \left[G_t \frac{\nabla \pi(A_t|S_t,\theta)}{\pi(A_t|S_t,\theta)} \right] \end{aligned}$$

  - De acuerdo a la **actualización por ascenso del gradiente**: $\theta_{t+1} = \theta_t + \alpha G_t \dfrac{\nabla \pi(A_t|S_t,\theta_t)}{\pi(A_t|S_t,\theta_t)}$

- **REINFORCE con Baseline**

$$\begin{aligned} H(\theta) &= \sum_s \mu(s) \sum_a (q_\pi(s,a) - b(s)) \nabla \pi(a|s,\theta) = \mathbb{E}_\pi \left[(G_t - b(S_t)) \frac{\nabla \pi(A_t|S_t,\theta)}{\pi(A_t|S_t,\theta)} \right] \\ &\text{porque } \textstyle\sum_a b(s) \nabla \pi(a|s,\theta) = b(s) \nabla \sum_a \pi(a|s,\theta) = b(s) \nabla 1 = 0. \end{aligned}$$

  - De acuerdo a la **actualización por ascenso del gradiente**: $\theta_{t+1} = \theta_t + \alpha (G_t - b(S_t)) \dfrac{\nabla \pi(A_t|S_t,\theta_t)}{\pi(A_t|S_t,\theta_t)}$

REINFORCE: Monte-Carlo Policy-Gradient Control (episodic) for π_*

Input: a differentiable policy parameterization $\pi(a|s, \boldsymbol{\theta})$
Algorithm parameter: step size $\alpha > 0$
Initialize policy parameter $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ (e.g., to $\mathbf{0}$)

Loop forever (for each episode):
  Generate an episode $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$, following $\pi(\cdot|\cdot, \boldsymbol{\theta})$
  Loop for each step of the episode $t = 0, 1, \ldots, T-1$:
    $G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ $\qquad (G_t)$
    $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \gamma^t G \nabla \ln \pi(A_t|S_t, \boldsymbol{\theta})$

- Fórmula anterior: $\theta_{t+1} = \theta_t + \alpha G_t \dfrac{\nabla \pi(A_t|S_t, \theta_t)}{\pi(A_t|S_t, \theta_t)}$
- Modificaciones en el psedocódigo:
  - Se incluyen los descuentos γ antes de G_0
  - $\nabla \ln \pi(a|s, \theta) = \dfrac{\nabla \pi(a|s, \theta)}{\pi(a|s, \theta)}$
- Al ser Monte Carlo tendrá varianza alta y aprendizaje lento.

REINFORCE con Baseline

REINFORCE with Baseline (episodic), for estimating $\pi_\theta \approx \pi_*$

Input: a differentiable policy parameterization $\pi(a|s, \boldsymbol{\theta})$
Input: a differentiable state-value function parameterization $\hat{v}(s, \mathbf{w})$
Algorithm parameters: step sizes $\alpha^{\boldsymbol{\theta}} > 0$, $\alpha^{\mathbf{w}} > 0$
Initialize policy parameter $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ and state-value weights $\mathbf{w} \in \mathbb{R}^d$ (e.g., to $\mathbf{0}$)

Loop forever (for each episode):
  Generate an episode $S_0, A_0, R_1, \ldots, S_{T-1}, A_{T-1}, R_T$, following $\pi(\cdot|\cdot, \boldsymbol{\theta})$
  Loop for each step of the episode $t = 0, 1, \ldots, T-1$:
    $G \leftarrow \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$ $\qquad (G_t)$
    $\delta \leftarrow G - \hat{v}(S_t, \mathbf{w}) \quad \longleftarrow \quad G_t - b(t) = G_t - v_\pi(S_t)$
    $\mathbf{w} \leftarrow \mathbf{w} + \alpha^{\mathbf{w}} \delta \nabla \hat{v}(S_t, \mathbf{w}) \quad \longleftarrow \quad \alpha^{\mathbf{w}} = \tau / \mathbf{x}(S_t)^\top \mathbf{x}(S_t)$
    $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha^{\boldsymbol{\theta}} \gamma^t \delta \nabla \ln \pi(A_t|S_t, \boldsymbol{\theta}) \quad \longleftarrow \quad \alpha^{\theta} = ??$

- Fórmula anterior: $\theta_{t+1} = \theta_t + \alpha(G_t - b(S_t)) \dfrac{\nabla \pi(A_t|S_t, \theta_t)}{\pi(A_t|S_t, \theta_t)}$
- Modificaciones en el psedocódigo:
  - Se incluyen los descuentos γ y $\nabla \ln \pi(a|s, \theta) = \dfrac{\nabla \pi(a|s, \theta)}{\pi(a|s, \theta)}$

Ejemplo Comparativo

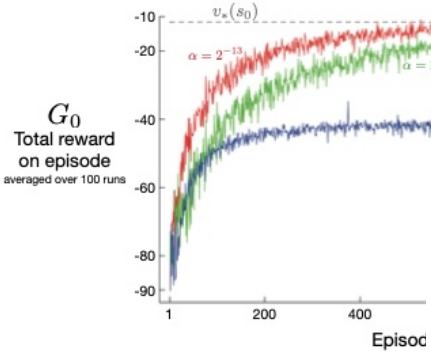

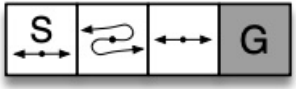

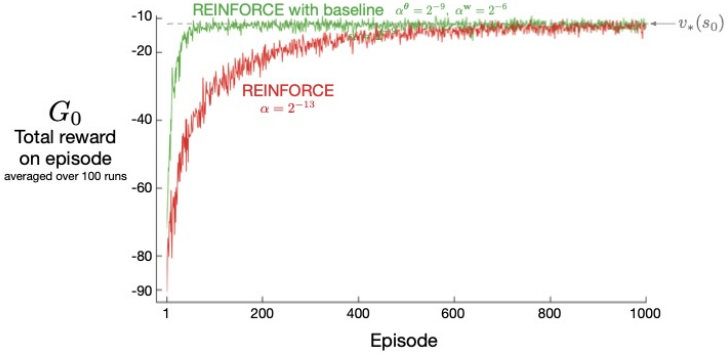

Desarrollo

1. Introducción

2. Fundamentos de los Métodos del Gradiente de la Política

3. REINFORCE

4. Métodos Actor–Crítico

5. Referencias

Métodos Actor-Crítico

- REINFORCE con Baseline es un método que aprende aproximaciones tanto para la política, $\widehat{\pi}(\boldsymbol{\theta})$, como para la función de valor, $\widehat{v}(S_t, \mathbf{w})$, usando Monte Carlo, G_t.
  - Usa como base una estimación del valor del estado $\widehat{v}(S_t, \mathbf{w})$
  - Usa el *error* $\delta \leftarrow G_t - \widehat{v}(S_t, \mathbf{w})$ para hacer una estimación del los parámetros $\mathbf{w}$ y $\boldsymbol{\theta}$
  - No evalúa directamente la acción tomada.
- La **función ventaja** nos ayuda a **criticar** la acción: $A_\pi(s, a) = q_\pi(s, a) - v_\pi(s) = \mathbb{E}[r + v_\pi(s')] - v_\pi(s)$
  - Error TD es un buen estimador: $A(s, a) = r + \gamma V(s') - V(s)$
- Un **Actor-Crítico** consta de dos componentes:
  - **Actor:** El modelo que se encarga de tomar una acción, $A_t \sim \pi(\cdot|S_t, \boldsymbol{w})$.
  - **Crítico:** La función de valor que se aplica **tanto al estado inicial como al estado siguiente** de la transición.
    - Evalúa el estado actual: $\widehat{v}(S_t, \mathbf{w})$ **¿La acción que tomó el actor fue buena?**
    - Evalúa directamente la acción tomada utilizando el retorno que produce en un paso. $G_{t:t+1} = R_{t+1} + \gamma \widehat{v}(S_{t+1}, \mathbf{w})$
- Actor-crítico usa el *error* $\delta_t \leftarrow G_{t:t+1} - \widehat{v}(S_t, \mathbf{w})$ para hacer una estimación del los parámetros $\mathbf{w}$ y $\boldsymbol{\theta}$.
- Los métodos A-C de un solo paso, **son análogos a** los métodos TD como TD(0), Sarsa(0) y Q-learning.
- **Características** de los métodos actor-crítico:
  - Son *bootstrapping*
  - Son totalmente e**n línea** e incrementales.
  - *Introducen* sesgo, pero *reducen* la varianza y *acelera* el aprendizaje.
  - Se pueden **generalizar** a n-pasos

Actor-Crítico de un paso (episódico)

One-step Actor–Critic (episodic), for estimating $\pi_\theta \approx \pi_*$

Input: a differentiable policy parameterization $\pi(a|s,\boldsymbol{\theta})$
Input: a differentiable state-value function parameterization $\hat{v}(s,\mathbf{w})$
Parameters: step sizes $\alpha^{\boldsymbol{\theta}} > 0$, $\alpha^{\mathbf{w}} > 0$
Initialize policy parameter $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ and state-value weights $\mathbf{w} \in \mathbb{R}^d$ (e.g., to $\mathbf{0}$)
Loop forever (for each episode):
  Initialize S (first state of episode)
  $I \leftarrow 1$
  Loop while S is not terminal (for each time step):
    $A \sim \pi(\cdot|S,\boldsymbol{\theta})$
    Take action A, observe S', R
    $\delta \leftarrow R + \gamma\hat{v}(S',\mathbf{w}) - \hat{v}(S,\mathbf{w})$ (if S' is terminal, then $\hat{v}(S',\mathbf{w}) \doteq 0$)
    $\mathbf{w} \leftarrow \mathbf{w} + \alpha^{\mathbf{w}}\,\delta\,\nabla\hat{v}(S,\mathbf{w})$
    $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha^{\boldsymbol{\theta}}\,I\,\delta\,\nabla\ln\pi(A|S,\boldsymbol{\theta})$
    $I \leftarrow \gamma I$
    $S \leftarrow S'$

Algunas Variantes del Actor-Crítico

Actor Crítico de n-pasos (n-step Actor-Critic) (R. Sutton & Barto, 2018)

- Extensión natural del Actor-Crítico de un paso.
- En lugar de usar la recompensa de un único paso y el valor estimado, se usan n pasos de experiencia.

Asynchronous Advantage Actor-Critic (A3C) (Mnih et al., 2016)

- Varios hilos (workers) corren en paralelo (de forma *asincrónica*), cada uno con su propia copia de la política (actor) y el crítico (función de valor).
- Cada worker interactúa con *su propio entorno*, generando estados, acciones y recompensas de forma independiente.
  - Cada uno tiene sus parámetros locales: $\mathbf{w}_{local}$, $\boldsymbol{\theta}_{local}$
- Se actualizan los parámetros globales de forma asíncrona.
  - $\boldsymbol{\theta}_{\text{global}} \leftarrow \boldsymbol{\theta}_{\text{global}} + \alpha \Delta \boldsymbol{\theta}_{\text{local}} \qquad \mathbf{w}_{\text{global}} \leftarrow \mathbf{w}_{\text{global}} + \beta \Delta \mathbf{w}_{\text{local}}$
- Sincroniza nuevamente los parámetros locales con los globales:
  - $\boldsymbol{\theta}_{\text{local}} \leftarrow \boldsymbol{\theta}_{\text{global}} \qquad \mathbf{w}_{\text{local}} \leftarrow \mathbf{w}_{\text{global}}$

Advantage Actor-Critic (A2C)

- A2C es la versión **síncrona** de A3C: varios trabajadores recolectan experiencias y actualizan la red de forma sincronizada.
- Todos los workers realizan N-pasos y actualizan los parámetros globales a partir de todos los parámetros locales.
  - $\boldsymbol{\theta}_{global} \leftarrow \boldsymbol{\theta}_{global} + \alpha \frac{1}{N} \sum_{i=1}^{N} \Delta \boldsymbol{\theta}^{(i)}, \qquad \mathbf{w}_{global} \leftarrow \mathbf{w}_{global} + \beta \frac{1}{N} \sum_{i=1}^{N} \Delta \mathbf{w}^{(i)}.$

Desarrollo

1. Introducción

2. Fundamentos de los Métodos del Gradiente de la Política

3. REINFORCE

4. Métodos Actor–Crítico

5. Referencias

Referencias

- Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., Silver, D., & Kavukcuoglu, K. (2016).Asynchronous Methods for Deep Reinforcement Learning. *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, 1928–1937.
- Silver, D. (2015). Lectures on Reinforcement Learning. https://www.davidsilver.uk/teaching/
- Sutton, R. S., McAllester, D., Singh, S. P., & Mansour, Y. (1999).Policy gradient methods for reinforcement learning with function approximation. *Advances in neural information processing systems, 12*, 1057–1063. https://papers.nips.cc/paper_files/paper/1999/hash/464d828b85b0bed98e80ade0a5c43b0f-Abstract.html
- Sutton, R. S., Singh, S., & McAllester, D. A. (2001).Comparing Policy-Gradient Algorithms. http://incompleteideas.net/papers/SSM-unpublished.pdf
- Sutton, R., & Barto, A. (2018). *Reinforcement Learning, second edition: An Introduction*. MIT Press. https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf
- Weng, L. (2018). Policy Gradient Algorithms. https://lilianweng.github.io/posts/2018-04-08-policy-gradient/